PHOTO-ILLUSTRATED EDITION / 2026.10.18

美国 AI 算力产业链

流程图 + 实物照片 + 公司关系

9 张流程图与 9 页对应配图相邻编排：先看关联，再看实物。

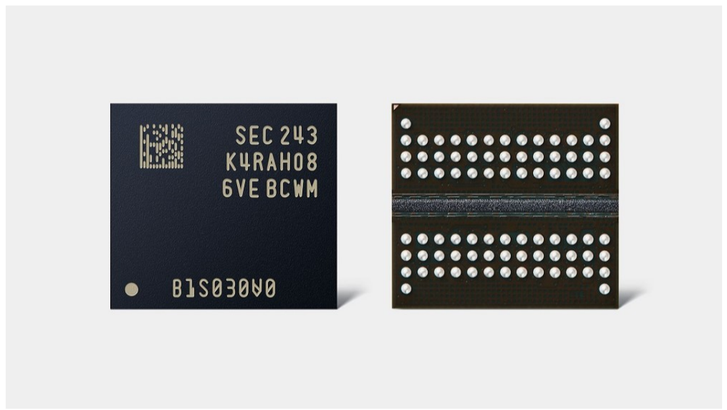

内存颗粒

P08 图片：Samsung Electronics

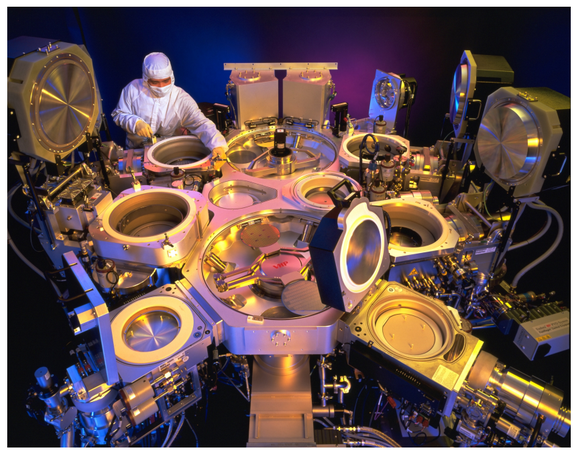

半导体设备

P02 图片：Applied Materials

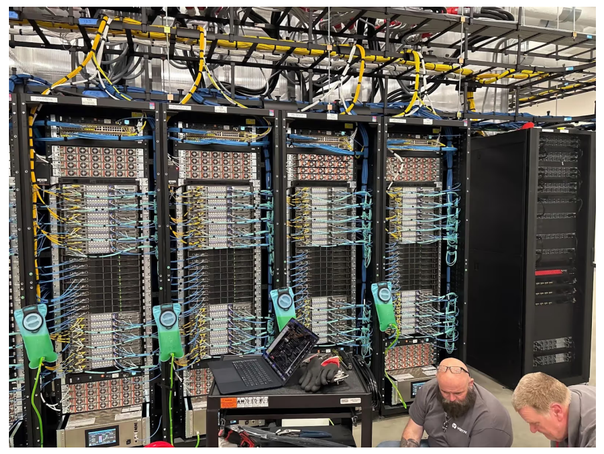

算力运营现场

P31 CoreWeave 官方资料

怎么阅读

总图 → 制造底座 → DDR5 内存条 → HBM → GPU / 显卡 → TPU → 其他定制 ASIC → 服务器 → 云与应用。

图像标识

实物 / 现场照片用于观察外观；官方产品图可能包含渲染；结构示意解释照片看不到的内部。所有图像保持原始比例。

来源与使用说明

每张配图保留提供方和可点击来源。型号用作工序与形态实例；不同代际、厂商和展品不自动构成同一产品的供应清单。

TPU v4 图片完整引文

Norman P. Jouppi, George Kurian, Sheng Li, Peter Ma, Rahul Nagarajan, Lifeng Nai, Nishant Patil, Suvinay Subramanian, Andy Swing, Brian Towles, Cliff Young, Xiang Zhou, Zongwei Zhou, and David Patterson. 2023. TPU v4: An Optically Reconfigurable Supercomputer for Machine Learning with Hardware Support for Embeddings: Industrial Product. In The 50th Annual International Symposium on Computer Architecture (ISCA ’23), June 17–21, 2023, Orlando, FL, USA. ACM, New York, NY, USA, 14 pages. https://doi.org/10.1145/3579371.3589350.

TPU v4 作者论文许可说明：个人/课堂学习用途，保留作者与出处；其他再利用需遵循原论文许可。

来源论文许可的中文说明（以原文为准）：

作者允许免费为个人或课堂用途制作该文全部或部分的数字或纸质副本，条件是副本不用于盈利或商业利益，且须在首页保留许可说明及完整引文。第三方组件的版权应受到尊重；其他用途应联系权利人。

原论文：TPU v4，Jouppi 等，ISCA 2023。图片来自作者公开稿；许可原文见来源首页。

美国 AI 算力全产业链：从芯片底座到应用

总图

阅读顺序：设计与制造 → 器件汇合 → 服务器/数据中心 → 三类算力运营者 → 模型与应用。

设计底座：EDA / IP

Synopsys、Cadence、Rambus、SiFive
Siemens EDA（德）、Arm（英）

工艺材料 / 硅片

Entegris、Qnity
信越、SUMCO、味之素（日本）等

设备 / 量测 / 测试

Applied Materials、Lam、KLA
Teradyne、FormFactor；ASML（荷）等

计算芯片：设计 → 晶圆

NVIDIA / AMD GPU、CPU
Google TPU；AWS / Microsoft / Meta ASIC
Broadcom / Marvell：定制合作
代工：TSMC 等；逻辑裸片输出

存储原厂：DRAM / NAND

Micron（美国）
SK hynix / Samsung（韩国）等
DDR / LPDDR、GDDR、HBM、SSD
具体存储形态按产品分流

互连 / 网络 / 电源器件

Broadcom、Marvell、Astera Labs
Credo、Coherent、Lumentum
TI、MPS；PCB / 连接器等
各自经过设计、晶圆与封测

HBM / GDDR

CPU / AI 加速器封装与模组

CPU 封装；GPU/ASIC + HBM 先进封装
TSMC、Amkor、ASE/SPIL 等参与
GPU 亦可走封装 + 板级 GDDR 路线

CPU 主机内存 / 存储

DDR → Micron / Kingston / SMART 模组
部分平台用 LPDDR / SOCAMM
NAND → SSD / 共享存储系统

网络 / 板卡 / 供电系统

Arista、Cisco、NVIDIA、HPE/Juniper
PCB、线缆、连接器、PSU 等
组件与系统按平台配套

服务器 / 机架集成：OEM、ODM 与云厂共同参与

Dell、HPE、Supermicro；Quanta/QCT、Wiwynn、Foxconn、Wistron（台）等
CPU + 加速器 + 内存 + SSD + 网络 + 供电/散热 → 系统验证与交付

机房设施 / 电力 / 冷却

Vertiv、Eaton、Schneider Electric 等
Equinix、Digital Realty、Core Scientific

AI 专用云

CoreWeave、Lambda、Crusoe 等
以商用 GPU 集群为主，运营与出租

综合云

AWS、Azure、Google Cloud、OCI
GPU 与各家自有 ASIC 路线并存

企业自用集群

Meta 等企业
自建与外部采购可同时存在

模型公司 / 模型 API / 云 AI 平台

OpenAI、Anthropic、Google 等模型厂
模型直供 API；Bedrock / Vertex AI / Foundry 分发
训练与推理可以采购一家或多家的算力

企业应用 / 开发者 / 最终用户

直接租算力自建模型，或调用模型 API
搜索、助手、编码、广告、客服、业务流程
Microsoft、Google、Salesforce、ServiceNow 等

TPU / Trainium / Maia 等各归其平台；CoreWeave 与综合云存在部分横向容量合作，详见分图 08。

蓝/青实线＝器件与硬件工序；紫实线＝算力/模型服务；灰虚线＝工具、材料、设施支持。同行参与者不表示可直接互换。

来源：分图 01-08 与全部来源目录。完整标题、链接及证据边界见图册附录。

看见 AI 算力产业链：从晶圆到机房

把原总图中的抽象节点，对应到可辨认的实物和现场。

阅读层级：晶圆 → 封装颗粒 / 计算模组 → 服务器 → 机架 → 持续运营

前道制造 P07 · 实物照片

01 晶圆：许多芯片的共同起点

Micron；图片由 IEEE Spectrum 发布

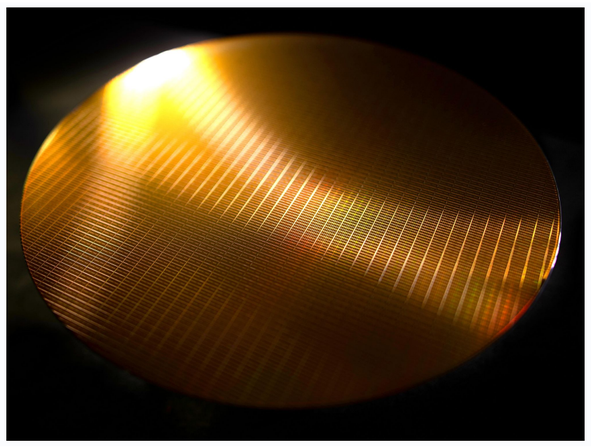

圆盘上有重复排列的芯片区域。图为美光 1β DRAM 晶圆，只作为晶圆形态示例。

图片：Micron Technology / IEEE Spectrum

封装后的器件 P08 · 官方产品图

02 封装：内存颗粒的正反面

Samsung DDR5 DRAM

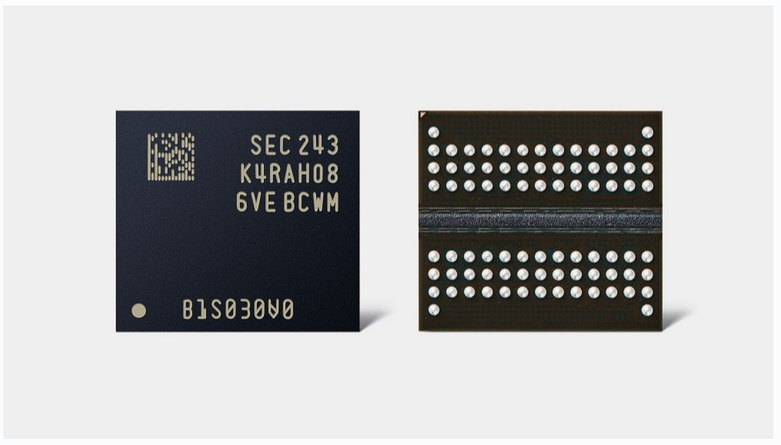

左边是封装顶面，右边是底部焊球；真正的 DRAM 裸片封在内部。

图片：Samsung Electronics

加速器模块 P15 · 产品渲染图

03 加速模组：GPU 与 HBM

NVIDIA H100 SXM5

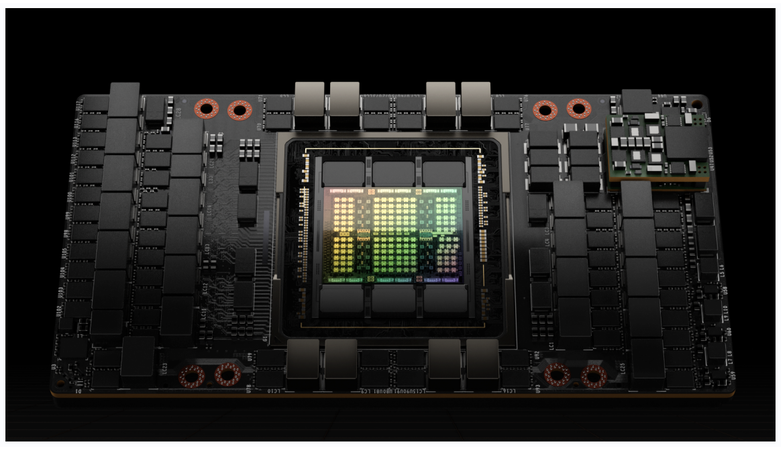

中央封装里有 GPU 与 HBM，外围电路板承担供电和连接；图为 H100 SXM 模组。

图：NVIDIA

系统集成 P25 · 产品实物图

04 整机：多种部件汇合

Supermicro SYS-421GE-TNRT

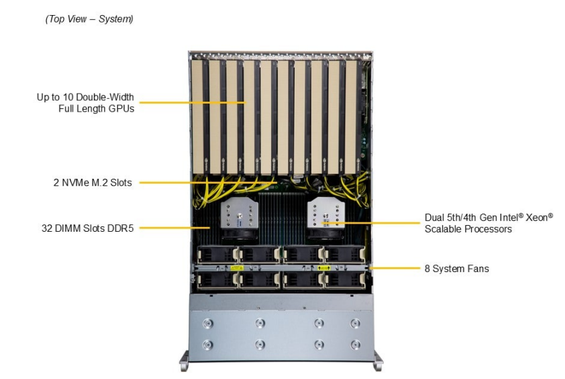

CPU、主机内存、GPU 板卡、存储和风扇进入同一服务器；这里采用 PCIe GPU 服务器实例。

Supermicro 官方资料

数据中心设施 P28 · 现场实拍

05 机架：计算与液冷连接

CoreWeave 现场；可见 Dell 标识

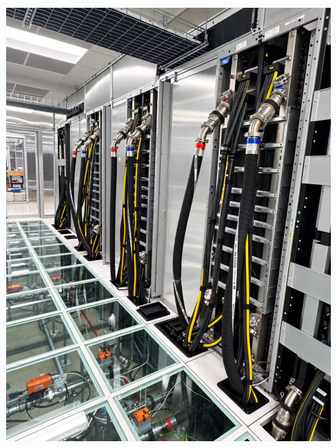

机架前方可见液冷软管、红蓝快接头和地板下管路，服务于整架设备的散热。

CoreWeave 官方资料

AI 云运营 P31 · 现场实拍

06 运营：把设备变成算力服务

CoreWeave 机房运维现场

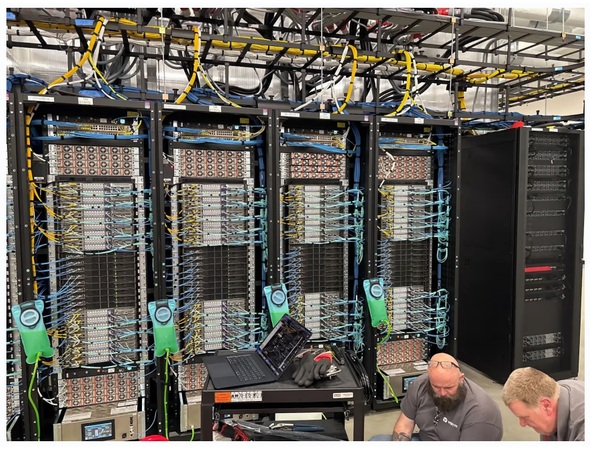

技术人员持续检查设备和冷却系统；调度、网络、存储与运维共同支持云服务交付。

CoreWeave 官方资料

01

芯片的共同底座：设计 → 晶圆 → 封装

美国设计和设备企业连接全球晶圆厂；逻辑芯片、DRAM 与模拟/功率器件在制造时分流。

设计流：交付芯片版图与制造数据

EDA 软件 / IP 授权
Synopsys、Cadence；Siemens EDA（德）
Arm（英）、Rambus、SiFive

架构与电路设计
NVIDIA、AMD、Broadcom、云厂商
存储原厂和模拟芯片厂也自行设计

验证、物理设计、流片
RTL / 仿真 → 布局布线 → 签核
向所选晶圆厂交付制造数据

版图 / 工艺数据

硅片与工艺材料
硅片：信越、SUMCO（日本）
材料/过滤：Entegris、Qnity
光刻胶、气体、CMP 材料等
输入晶圆厂的洁净制造过程

晶圆制造：反复加工
薄膜沉积 → 光刻 → 刻蚀/掺杂
清洗 / CMP → 金属互连
上述步骤按设计多次循环
量测与缺陷控制贯穿全过程

制造设备与工艺控制
Applied Materials：沉积、CMP 等
Lam Research：刻蚀、沉积、清洗
ASML（荷兰）：光刻；TEL（日）
KLA：检测、量测、良率控制

逻辑晶圆：GPU / CPU / ASIC
TSMC（中国台湾）是关键参与者
Intel Foundry、Samsung（韩）亦供代工
具体产品按已披露代际判断

存储晶圆：DRAM / NAND
Micron（美国）
SK hynix、Samsung（韩国）
存储原厂负责自己的芯片制造

模拟 / 互连 / 功率器件
TI、MPS 等芯片企业；部分外包
GlobalFoundries 等特色工艺厂
芯片功能决定工艺，并非全用最小节点

晶圆电测 → 切割 → 封装集成 → 成品测试
封装：TSMC、Amkor、ASE/SPIL（中国台湾）等；载板见附录
测试设备/探针卡：Teradyne、FormFactor、Advantest（日本）

简化流程：测试贯穿多个阶段；TSMC 的先进逻辑代工不等于替各存储原厂制造全部 DRAM。

来源：S01-S10、S54-S60。完整标题、链接及证据边界见图册附录。

半导体设备长什么样：六类关键现场与设备

设备外观用于认识分工；光刻、沉积、刻蚀与检测会在制造中多轮配合。

对应分图 01：设备装配 / 光刻 / 薄膜沉积 / 刻蚀 / 缺陷检测 / 电性测试

图形化 P01 · 官方产品图

光刻机：把图形转移到光刻胶

ASML TWINSCAN NXE:3400C

光刻机通过光学系统把掩模图形转移到光刻胶上。NXE:3400C 是设备外观的历史型号示例。

图片：©ASML

薄膜制造 P02 · 实物照片

沉积设备：在表面形成薄膜

Applied Materials Endura PVD

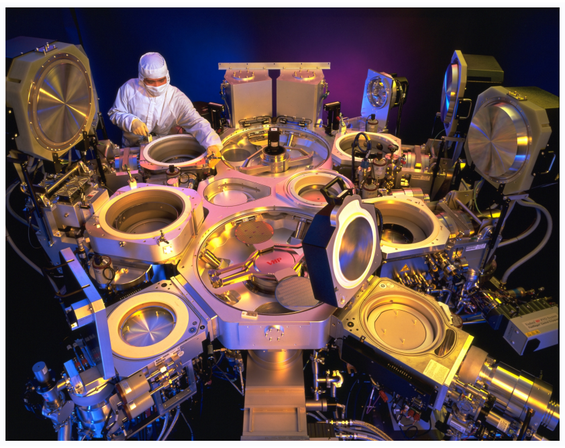

中央搬运机构连接多个真空腔体；PVD 用来沉积金属等薄膜。这张图展示腔体打开时的设备结构。

图片：Applied Materials

图形转移 P03 · 实物照片

刻蚀机：有选择地去除材料

Lam Research Versys Kiyo45

刻蚀设备有选择地去除材料，形成沟槽等结构。图为成熟平台 Kiyo45，用于辨认设备类别。

图片：Lam Research

过程控制 P04 · 官方产品图

检测设备：寻找晶圆上的缺陷

KLA 3935 / 2965 BBP

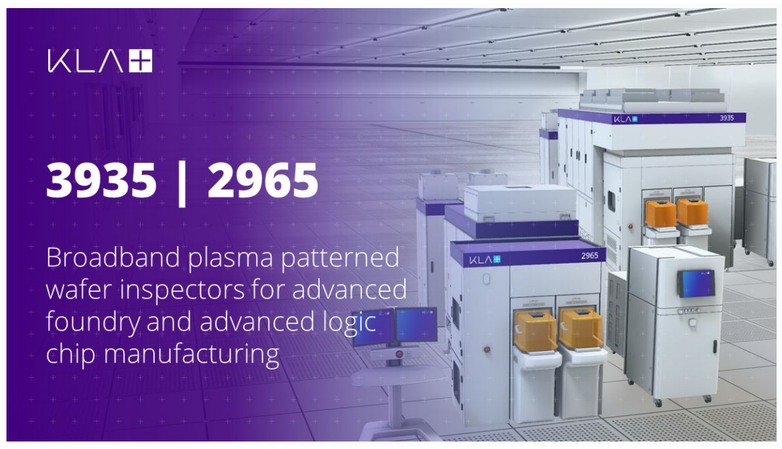

光学检测设备寻找晶圆上的缺陷，帮助监控制造良率；图中橙色容器位于晶圆装载端。

图片：KLA

器件测试 P05 · 官方产品图

测试机：检查电信号与功能

Teradyne Magnum 7H

测试系统向器件施加电信号并检查响应，覆盖 HBM 基础裸片、堆叠前后等制造测试环节。

图片：Teradyne

设备生产 P06 · 现场实拍

洁净室：设备制造现场

ASML 设备装配现场

技术人员在洁净室内装配设备模块。图为半导体设备制造现场，不是 DRAM 晶圆生产线。

图片：©ASML

02

内存条如何制造：从 DRAM 颗粒到服务器 DIMM

先制造存储芯片，再将芯片、接口器件与 PCB 装成模组；金士顿与美光承担的角色不同。

A 存储芯片原厂：提供容量

DRAM 电路设计
Micron
SK hynix / Samsung（韩）

→

DRAM 晶圆制造
存储原厂晶圆厂
沉积、光刻、刻蚀等反复加工

→

晶圆电测 / 切割
筛选良品与速度等级
使用测试机、探针卡

→

颗粒封装 / 测试
BGA 等 DRAM 封装
部分高容量产品采用堆叠裸片

合格 DRAM 颗粒 ↓

B 模组厂：把颗粒变成一根可插拔的内存条

PCB / 结构 / 平台规格
多层电路板、金手指、被动器件
按 Intel / AMD 等平台要求设计
容量、布线、供电和信号完整性
部件兼容性需逐项验证

⇢

模组设计与物料齐套
原厂模组：Micron 等
独立模组：Kingston、SMART Modular
SMART 为 Penguin Solutions 品牌
合并 DRAM、PCB 和配套芯片

←

接口与管理芯片供料
Rambus（美）、Renesas（日）
Montage / 澜起（中国）
RDIMM：RCD、PMIC、SPD Hub、TS
MRDIMM：MRCD、MDB
同样需要 PMIC、SPD Hub、TS

↓

SMT 贴装 / 回流焊
锡膏印刷 → 贴装芯片
回流焊 → 光学检查

→

配置写入 / 电性测试
写入 SPD 配置
检查容量、时序、速度和功能

→

平台验证 / 老化
检查主板 / CPU / BIOS 兼容
服务器负载与可靠性测试

→

成品内存条
DDR5 RDIMM / MRDIMM
插入主板，作为 CPU 主机内存

可公开核对的供货关系
Kingston 官方列出 Micron、SK hynix、Samsung 为 DRAM 供应商。模组厂采购颗粒后完成设计、装配与验证；不能据此认定某一型号同时使用三家的颗粒。

RCD 缓冲命令/地址/时钟；PMIC 管电源；SPD 存配置；TS 测温；MRCD/MDB 用于多 Rank 复用。

来源：S11-S15。完整标题、链接及证据边界见图册附录。

内存颗粒怎样变成一根服务器内存条

看清四个层级：晶圆、封装颗粒、模组电路板、主板内存插槽。

对应分图 02：晶圆 → 切割封装 → 模组装配 / 测试 → RDIMM → 服务器插槽

制造输出 P07 · 实物照片

01 切割前：DRAM 晶圆

Micron；图片由 IEEE Spectrum 发布

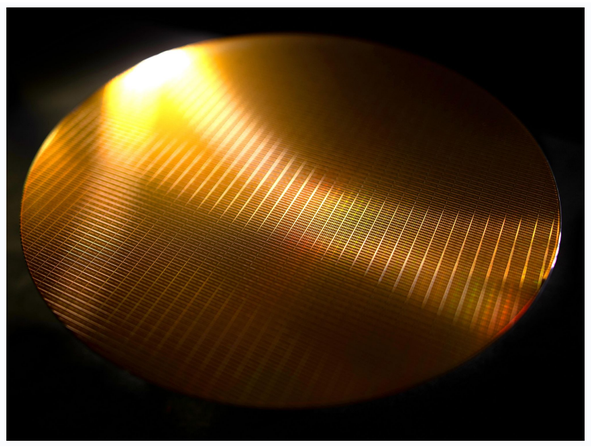

许多 DRAM 芯片区域排在一张晶圆上。图为 1β DRAM 形态示例，原报道介绍 LPDDR5X。

图片：Micron Technology / IEEE Spectrum

颗粒 P08 · 官方产品图

02 切割封装后：单颗 DRAM

Samsung 12nm 级 DDR5 产品图

正面有厂商与批次标识，底面有 BGA 焊球。内存条上常见的黑色方块就是这一类封装。

图片：Samsung Electronics

模组制造 P09 · 实物照片

03 模组生产与测试现场

Kingston Technology

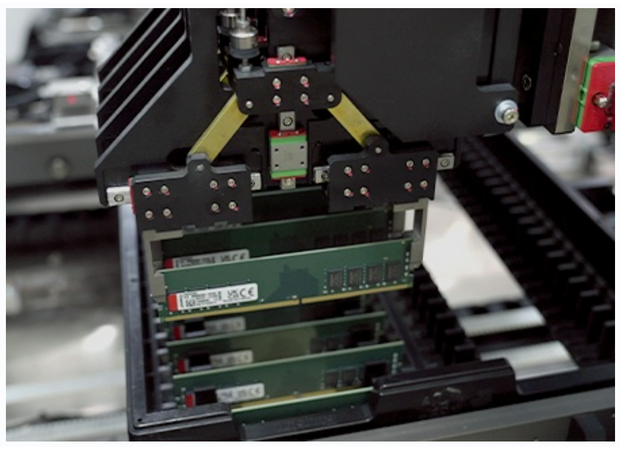

图中是一批内存模组及生产设备。装配后还要完成相应功能、兼容性和可靠性检查。

图片：Kingston Technology

服务器内存条 P10 · 官方产品图

04 成品：DDR5 RDIMM

Micron 128GB DDR5 RDIMM

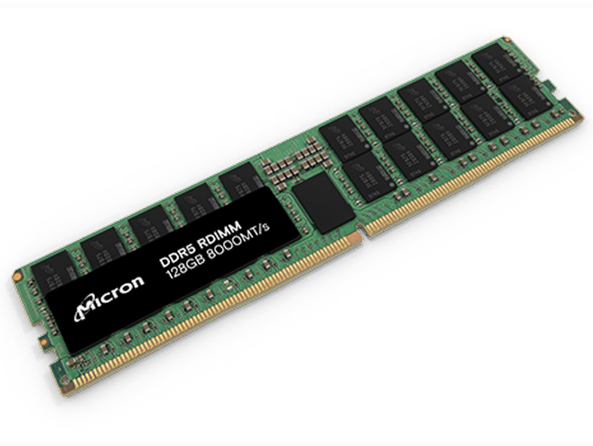

PCB 上有 DRAM 颗粒及配套器件；下方金手指用于连接主板。本图用于辨认外观。

图片：Micron Technology / Mynavi TECH+

整机安装 P14 · 实物照片

05 内存条放到主板哪里

SK hynix 展示的 Dell PowerEdge R770

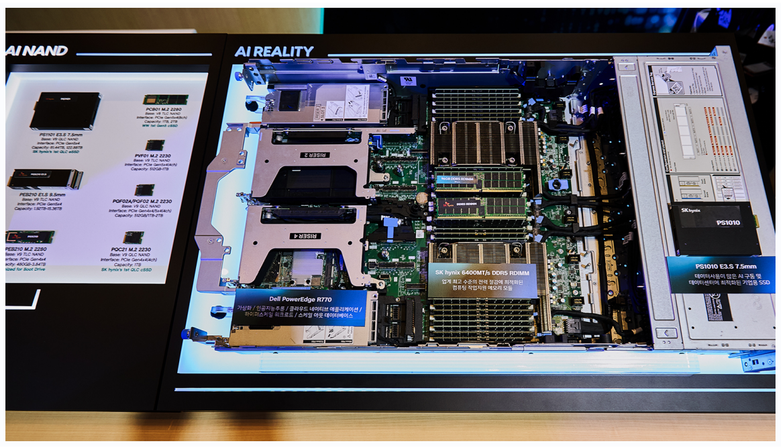

实际内存插槽排在 CPU 散热器旁；散热器上方横放的两条是展品，不能当作安装位置。

图片：SK hynix / DTF 2026

尺寸与形态对照 P13 · 实物照片

06 同场对照：晶圆与多种内存

SK hynix / DTF 2026

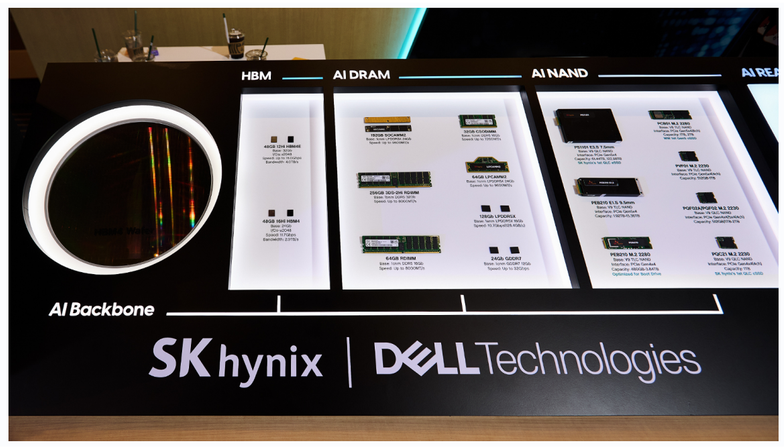

展台同时展示 HBM 晶圆、HBM 产品、DDR5 模组和 GDDR 颗粒；它们处于不同层级。

图片：SK hynix / DTF 2026

HBM 如何制造：先堆存储，再与计算芯片封装

HBM 也是 DRAM；它通常集成在高端 AI 加速器封装中，连接方式与 CPU 内存条不同。

HBM 专用 DRAM 晶圆
Micron（美国）
SK hynix / Samsung（韩国）
按 HBM 带宽、容量、功耗协同设计

基础裸片：并行制造
接口、逻辑及测试等功能
已公开例子：SK hynix HBM4
基础裸片采用 TSMC 逻辑工艺

测试设备与探针卡
FormFactor（美）：探针卡
Teradyne（美）/ Advantest（日）
提供 HBM 电性测试设备

TSV / 晶圆电测 / 减薄
形成垂直连接的硅通孔
筛选良品、背面处理、互连加工
减薄与切割；顺序随工艺变化
减薄/切割设备：DISCO（日本）

堆叠 / 键合 / 填充
多层 DRAM + 基础裸片
对准、键合、形成垂直电连接
SK hynix MR-MUF 为一种公开路线

HBM 堆栈测试
功能、速度、互连与可靠性验证
输出经过筛选的 HBM 堆栈
在此前后的多个阶段均有测试

合格 HBM 堆栈

GPU / ASIC 逻辑裸片
来自计算芯片制造链
NVIDIA、AMD、Google / 云厂 ASIC
设计方与代工方承担不同职责

先进封装：多路汇合
逻辑裸片 + HBM + 中介层/载板
代表：TSMC CoWoS
封装后测试，再进入板卡/模组

中介层 / 封装载板
TSMC 中介层/局部互连技术等
载板：IBIDEN（日）、欣兴（台）等
ABF 绝缘材料：味之素（日本）

公开产品采用
Micron HBM4 → NVIDIA Vera Rubin
SK hynix HBM3E → NVIDIA GB300
仅为供货例子，不代表独家。

AI 加速器封装 / 模组
送入 GPU/ASIC 板卡、计算托盘及服务器

三类内存的典型位置
DDR5 DIMM：CPU 主板插槽
GDDR：通常焊在显卡 PCB
HBM：计算裸片旁的高密度封装

此图为常见 HBM 工艺的简化合并，不能把 MR-MUF、堆叠层数或具体设备视为所有厂商的统一工艺。

来源：S07、S10、S16-S20、S54。完整标题、链接及证据边界见图册附录。

HBM 长什么样：外观、内部堆叠与计算封装

产品外观通常看不到 TSV 和层间连接，因此加入一张明确标注的结构示意。

对应分图 03：晶圆 → 减薄 / 堆叠 / 键合 → HBM 测试 → 与 GPU / ASIC 封装集成

晶圆 P13 · 实物照片

01 实际 HBM 晶圆展品

SK hynix / DTF 2026

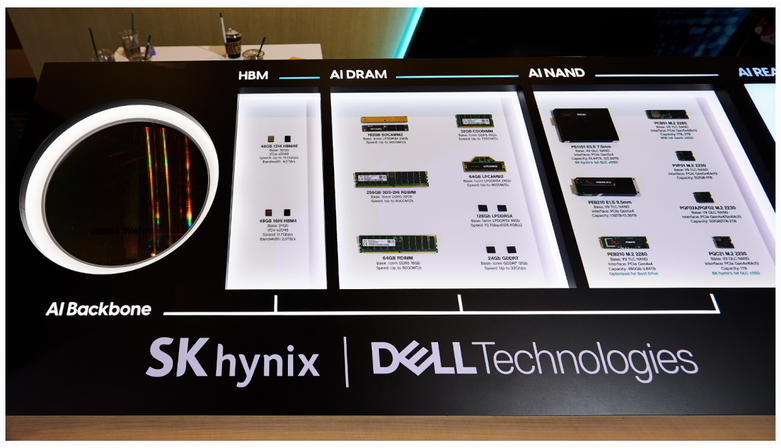

左侧是官方确认的 HBM4 晶圆实物；展台展示颗粒和模组，用来观察不同形态。

图片：SK hynix / DTF 2026

堆叠 / 键合 P11 · 结构示意

02 里面为何有多层芯片

SK hynix 官方结构图

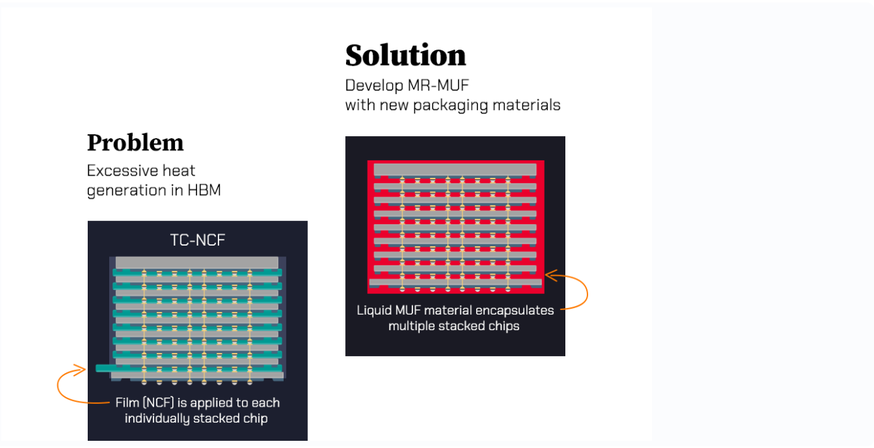

示意图对比 TC-NCF 与 MR-MUF 的堆叠填充方式。不同厂家和产品不必使用同一方案。

结构图：SK hynix

HBM 成品 P12 · 官方产品图

03 完成堆叠后的 HBM 外观

SK hynix HBM3E

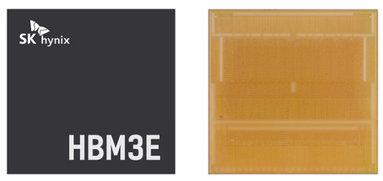

黑色小方块是 HBM3E 产品。内部的多层 DRAM 与连接结构，在外观照片中看不到。

图片：SK hynix

电性测试 P05 · 官方产品图

04 制造过程中仍然需要测试

Teradyne Magnum 7H

Magnum 7H 用于 HBM 基础裸片及堆叠相关测试；图中是测试设备，不是存储器本体。

图片：Teradyne

先进封装 P18 · 实物照片

05 HBM 与计算芯片放在一起

Google / Jouppi 等，TPU v4

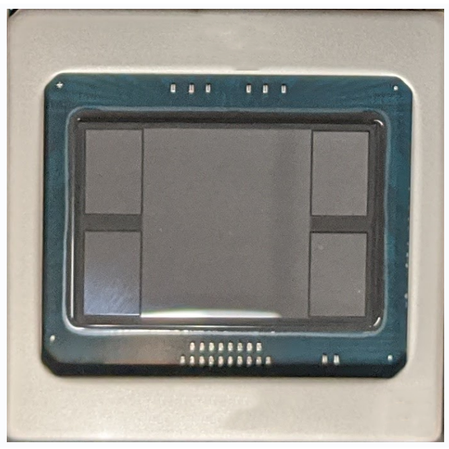

TPU v4 封装实拍：中央为 ASIC，两边共四个 HBM 堆栈。这里展示封装内的并排关系。

图：Google；Jouppi 等作者

模组 / 服务器 P15 · 产品渲染图

06 封装进入加速模组

NVIDIA H100 SXM5

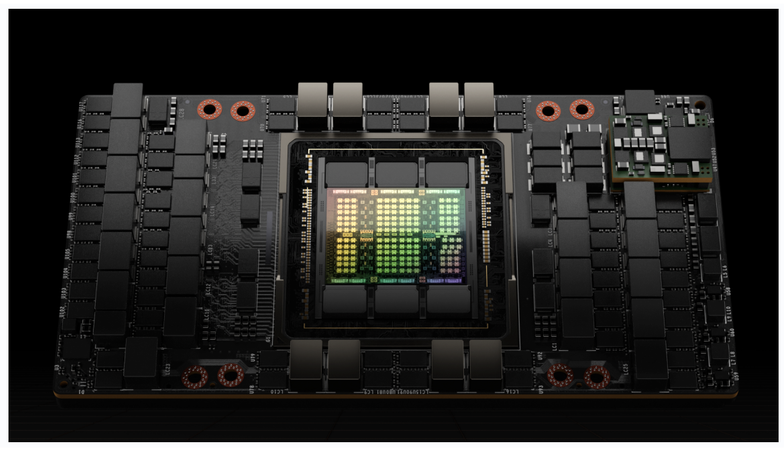

H100 的 GPU 与 HBM 封装进入 SXM 模组，再与底板和服务器集成；外围器件负责供电等。

图：NVIDIA

GPU 如何成为显卡与 AI 加速器

共同经历芯片设计与制造；之后按产品走 GDDR 板卡或 HBM 高密度封装等路线。

NVIDIA / AMD 设计
计算架构、芯粒、显存接口
CUDA / ROCm 配套开发

EDA / 验证 / 流片
逻辑实现、布局布线
签核后交付版图

晶圆代工
关键参与者：TSMC（台）
Blackwell Ultra：TSMC 4NP

晶圆电测 / 切割
取得合格 GPU 裸片 / Chiplet
进入不同产品封装路线

路线 A GDDR 显卡 / 专业或推理 GPU

GPU 封装 + 板级 GDDR 颗粒
GPU 先完成自身封装；GDDR 来自 Micron / SK hynix / Samsung
GDDR 颗粒独立封装后，与 GPU 一同焊在显卡 PCB 上
另需 PCB、供电芯片、连接器与被动器件

显卡制造：SMT、散热器、固件与整卡测试
NVIDIA 公版；PNY（美）；ASUS / MSI / GIGABYTE（台）等
示例：GeForce RTX 50 使用 GDDR7
具体 GPU 伙伴名单和颗粒来源随品牌、型号变化

PCIe 显卡 → PC / 工作站 / 部分服务器
用途覆盖图形、内容创作、本地 AI 与部分推理工作负载

路线 B HBM 高端 AI 加速器

GPU 裸片 + HBM + 中介层/载板
GPU 逻辑裸片与 HBM 堆栈在先进封装中汇合
代表方案：TSMC CoWoS；封装后再次测试
HBM 的 DRAM 制造及堆叠见图 03

加速模组 → 底板 / 计算托盘
NVIDIA SXM → HGX；AMD OAM → UBB
也有采用 PCIe 形态的数据中心加速卡
加上 CPU、主机内存、网络、SSD、供电与散热

Dell / HPE / Supermicro / ODM → AI 机架
系统集成与验证后，交付算力运营商、综合云和企业

边界：数据中心 GPU 并非全部采用 HBM；例如 NVIDIA RTX PRO 6000 Blackwell Server Edition 采用 GDDR7。

GPU 是芯片/处理器；显卡是板级产品；SXM/OAM 是模组形态；HGX/UBB 是更高一层的系统底板。

来源：S07、S19、S21-S24。完整标题、链接及证据边界见图册附录。

显卡与 AI 加速器：从封装看到整机

同属 GPU 系统，消费显卡、SXM 模组与超级芯片板的外形差别很大。

对应分图 04：GPU + GDDR → 显卡；GPU + HBM → 加速模组 → 系统

数据中心路线 P15

产品渲染图

GPU + HBM：SXM 加速模组

NVIDIA H100 SXM5

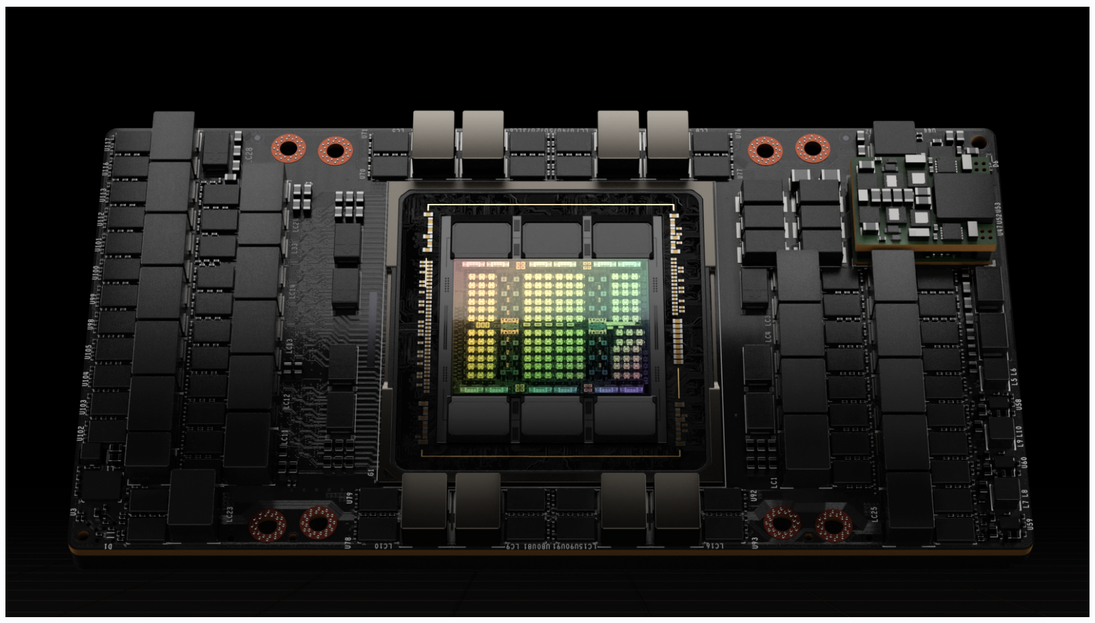

中央 GPU 与周围 HBM 形成计算封装，再装到带供电和连接电路的 SXM 模组上。

图：NVIDIA

GDDR 显卡路线 P16

产品渲染图

完整显卡：外壳与散热器

NVIDIA RTX 5090 Founders Edition

成卡的散热器遮住 GPU 与显存。RTX 5090 属于 GDDR7 显存路线。

图：NVIDIA

另一代系统实例 P17

官方产品图

CPU、GPU 与网络的板级组合

NVIDIA GB300 Grace Blackwell Ultra

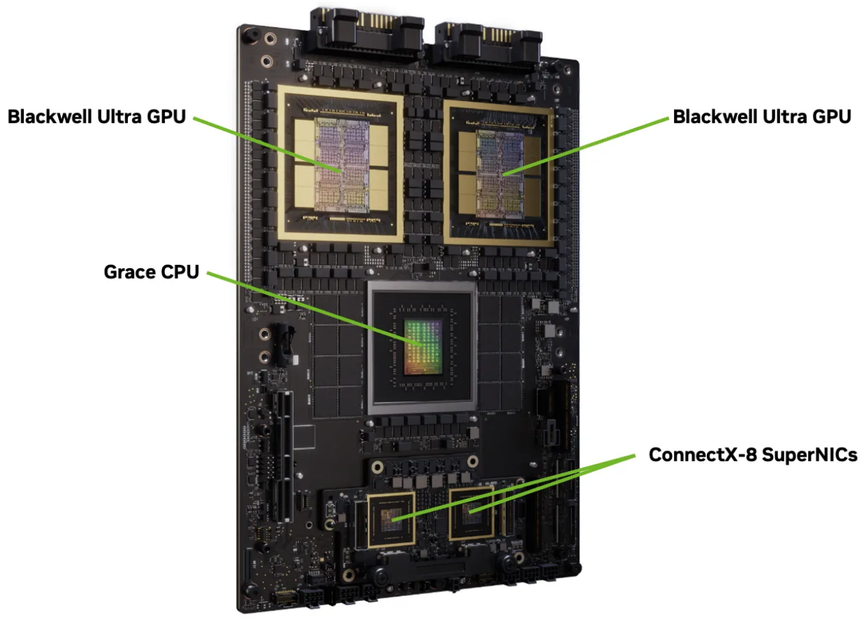

原图标出两颗 Blackwell Ultra GPU、Grace CPU 和 ConnectX-8 SuperNIC；这是一套系统模组。

图：NVIDIA

整机交付 P26

产品实物图

加速器进入服务器整机

Supermicro SYS-421GE-TNRT

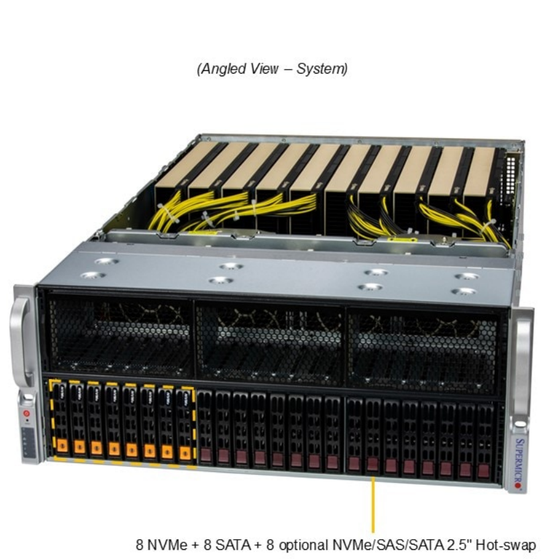

整机把加速器与主机、内存、存储、供电及风扇组织起来，再进入机架部署。

Supermicro 官方资料

05

Google TPU：定制 ASIC → 托盘 → Pod → 云

TPU 属于定制 AI ASIC。公司级合作已公开，但不能据此补全每代 TPU 未披露的制造清单。

Google：需求 / 架构 / 软件

定义模型工作负载、计算与互连
协同开发编译器和运行时
TPU 是专用 AI 加速器产品线

Broadcom：定制 TPU 合作

2026-04 SEC 文件确认：
为 Google 未来多代 TPU 开发与供应
并供应下一代 AI 机架的网络等组件

逻辑实现 / 验证 / 流片

芯片设计团队与 EDA / IP 生态
完成物理设计、签核
交付晶圆制造数据

晶圆制造 / 测试 / 封装

外部晶圆制造 → 逻辑裸片
合格 TPU ASIC + HBM → 封装
具体代际的代工、HBM、OSAT 分工
需要按产品公开资料进一步确认

已披露的是 Broadcom 公司级制造伙伴池

FY2025 年报披露 TSMC 等晶圆制造伙伴。
组测伙伴包括 TSMC、ASE、Amkor、SPIL、Foxconn 等。
这份公司级名单没有将每一家绑定到某一款 TPU，不等于型号级供货清单。

公开物理架构实例：TPU v4，统一使用同一代数据

1 个 TPU 封装

中央 ASIC + 4 个 HBM 堆栈
论文披露 7nm 工艺

1 块液冷 PCB

4 个 TPU 封装
配套 CPU Host / 托盘

1 个机架

16 组托盘 / Host
共 64 个 TPU

完整 TPU v4 系统

64 个机架 / 4096 个 TPU
ICI 与光交换 OCS 互联

TPU Pod / Slice → Google Cloud

Cloud TPU VM、GKE、Vertex AI；也支持 Google 内部模型和业务使用

产品代际说明

v4 数量只作制造到系统层级的完整例子；
不表示它是最新 TPU，也不套用到其他代。

Google 与 Broadcom 的开发/供应合作有直接披露；制造伙伴池是公司级信息，不能代替 TPU 的具体 BOM。

来源：S25-S28。完整标题、链接及证据边界见图册附录。

Google TPU：同一代产品的三个物理层级

以下三张都来自 TPU v4 作者论文，保持封装、板卡、机架的代际一致。

对应分图 05：TPU v4 封装 → 四芯片液冷板 → 托盘与机架 → Pod / Slice

Figure 2 左图 P18

实物照片

01 单个 TPU v4 封装

Google / Jouppi 等，ISCA 2023

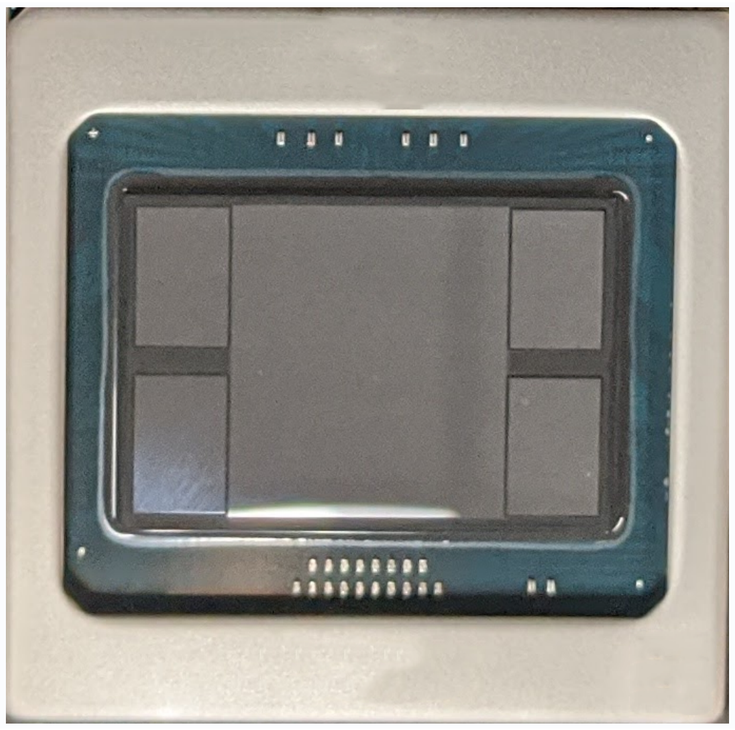

中央是计算 ASIC，两侧共有四个 HBM 堆栈。封装表面能直接看出二者的相邻关系。

图：Google；Jouppi 等作者

Figure 2 右图 P19

实物照片

02 一块板上有四个 TPU

Google / Jouppi 等，ISCA 2023

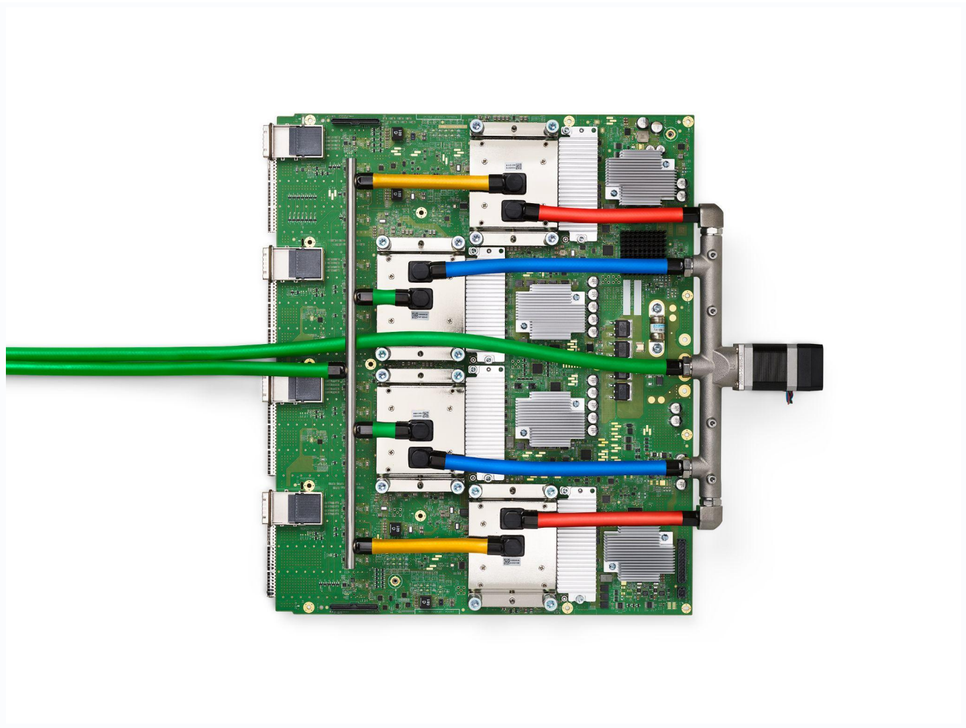

四颗封装通过板卡、液冷管路和连接接口形成下一层级的计算单元。

图：Google；Jouppi 等作者

Figure 3 P20

实物照片

03 机架组成更大的 TPU 系统

Google / Jouppi 等，ISCA 2023

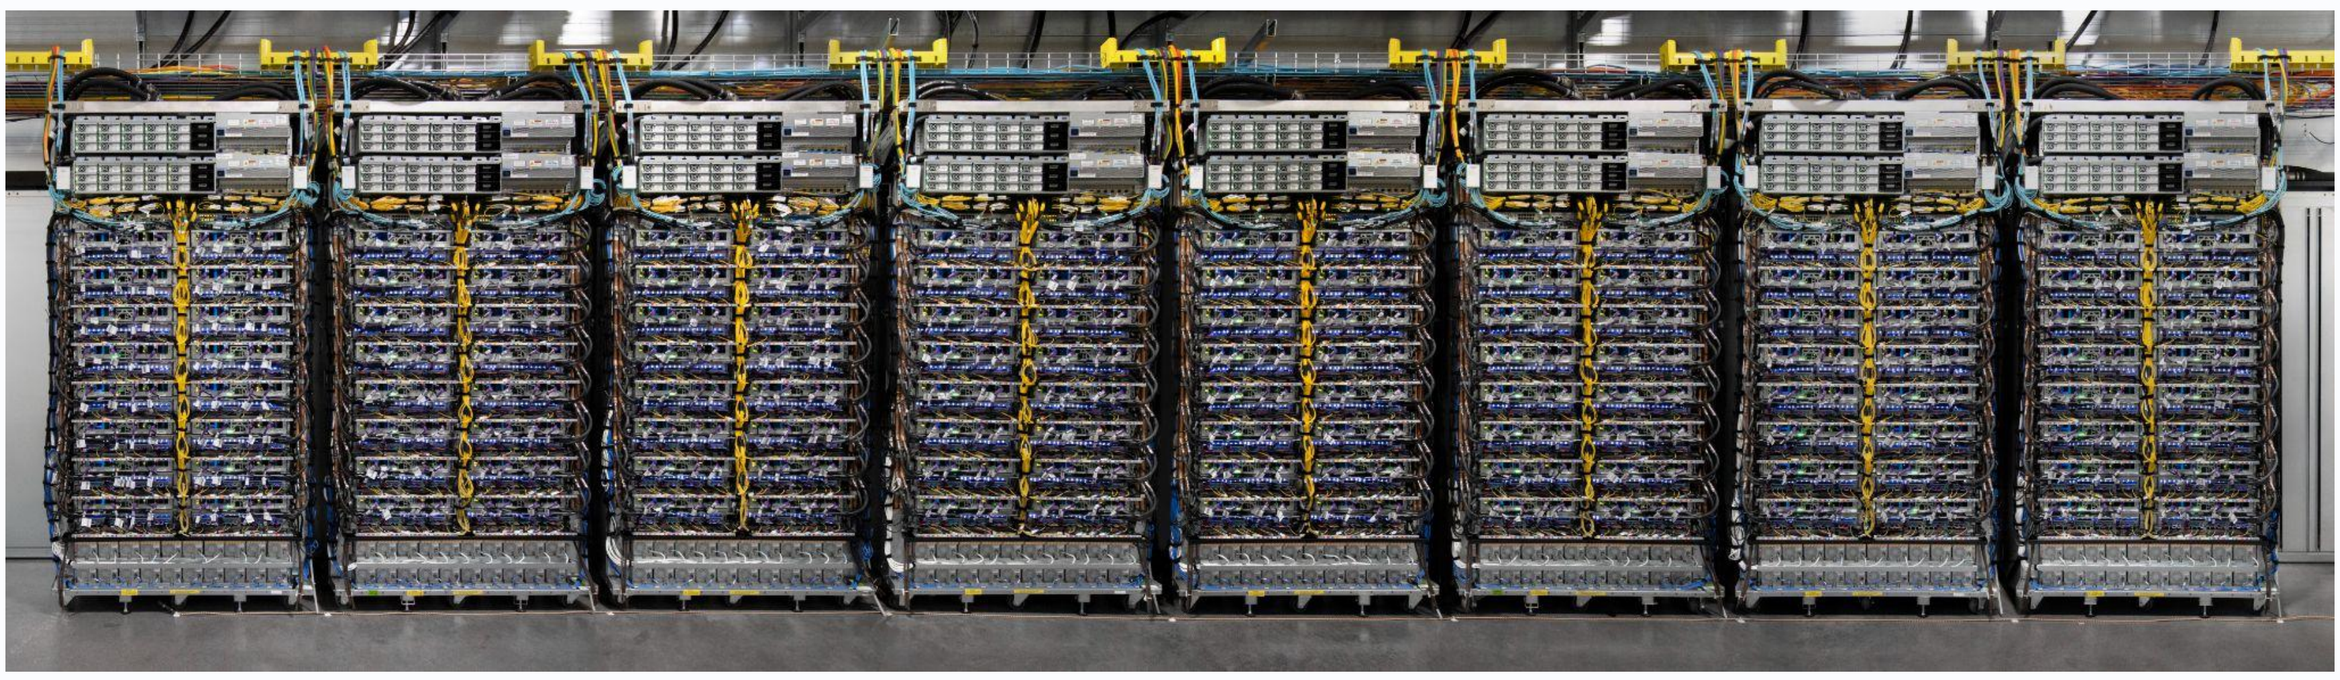

图中是八个机架，占论文所述 64 机架、4096 芯片 TPU v4 系统的八分之一。

图：Google；Jouppi 等作者

TPU v4 用于完整展示物理层级；不是最新代际。作者论文完整引文与许可说明见本图册首页。

其他定制 AI 芯片：云厂商自研 + 产业伙伴

AWS、Microsoft、Meta 的需求和服务出口不同；定制芯片也不必统一采用 HBM。

需求 / 架构定义
云厂商定义计算、能效和成本
结合模型与软件栈设计

→

设计 / IP / 验证
自研 + 按项目引入设计伙伴
片上 SRAM 与内存接口设计

→

流片 / 晶圆 / 封装
代工、裸片测试与封装
HBM/LPDDR 按封装或板级配置

→

板卡 / 系统 / 软件
服务器与互连、供电、散热
编译器、运行时、集群验证

三条公开产品路径：每列内部是同一体系

AWS · Annapurna Labs

Trainium：训练与推理
Inferentia：推理
Marvell 有 AWS 定制 AI 产品合作

↓

制造与内存：Trainium 体系
TSMC 已确认 Trainium 使用 CoWoS
Trainium2 / Trn2 采用 HBM3
16 芯片实例 / 64 芯片 UltraServer
NeuronLink、EFA 组成集群

↓

AWS 云服务
EC2 / SageMaker 等
Neuron 软件栈配套

Microsoft · Maia

微软定义并自研 AI 加速器
Maia 200：推理用途的公开例子
不补入未披露的设计外包方

↓

Maia 200 公开结构
TSMC 3nm；HBM3e
加速器托盘与 Ethernet 集群
按 Azure 数据中心整体设计部署
软件工具与硬件同步优化

↓

Microsoft 云与应用
Azure / Foundry、Copilot
及内部模型业务

Meta · MTIA

Meta 自研 AI 计算体系
2026 年已公布 Broadcom 合作
覆盖芯片设计、封装与网络

2024 年结构示例 ↓

MTIA 的内存随代际变化
2024 年公开 MTIA：
TSMC 5nm + LPDDR5
板卡 → 机架 → 自用集群
这一配置不套用至后续代际

↓

Meta 内部业务
推荐、广告及其他 AI 业务
自用角色，不是通用云实例商

新进入者例子：OpenAI 与 Broadcom 已宣布自研加速器合作；规划部署不等于已完成交付，未披露制造分工不作补全。

合作范围不能扩大解释：Marvell-AWS 公告并未据此确认某代 Trainium 由 Marvell 独家设计。

来源：S07、S29-S34。完整标题、链接及证据边界见图册附录。

定制 AI 芯片的实物：芯片封装与服务器托盘

AWS、Microsoft、Meta 等公司围绕自己的工作负载定义芯片与系统。

对应分图 06：需求 / 设计 → 晶圆与封装 → 板卡 / 托盘 → 各自云平台或内部业务

AWS 产品实例 P21 · 实物照片

AWS Trainium2：手中的芯片

Amazon / AWS Annapurna Labs

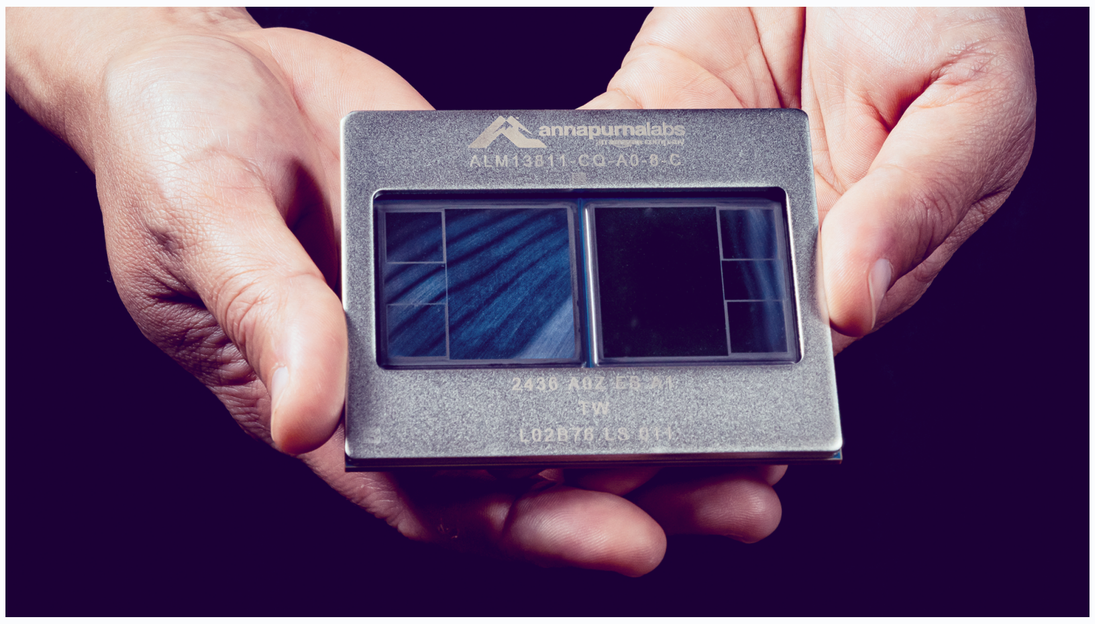

这是 Trainium2 芯片封装实拍。双手提供直观大小参照，不能从照片推断全部内部规格。

图：Amazon / AWS

Microsoft 芯片 P22 · 实物照片

Microsoft Maia 200：芯片近景

Microsoft Maia 200

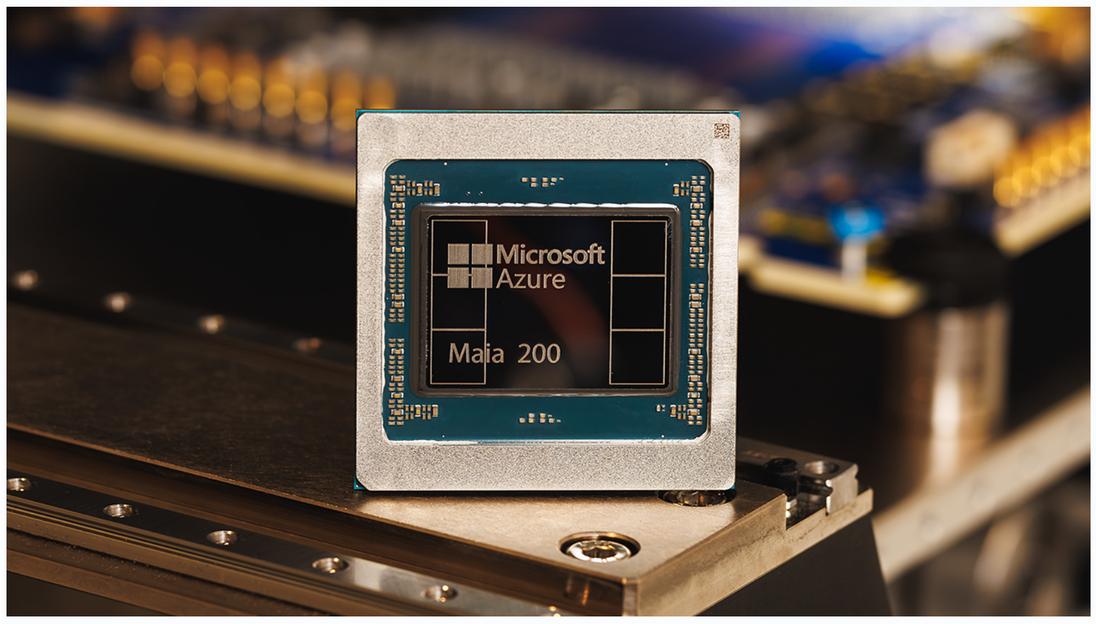

图中是微软自研 AI 推理加速器的封装外观，品牌标识与封装基板清晰可见。

图：Microsoft

Microsoft 系统 P23 · 实物照片

Maia 200：从芯片到托盘

Microsoft Maia 200 server blade

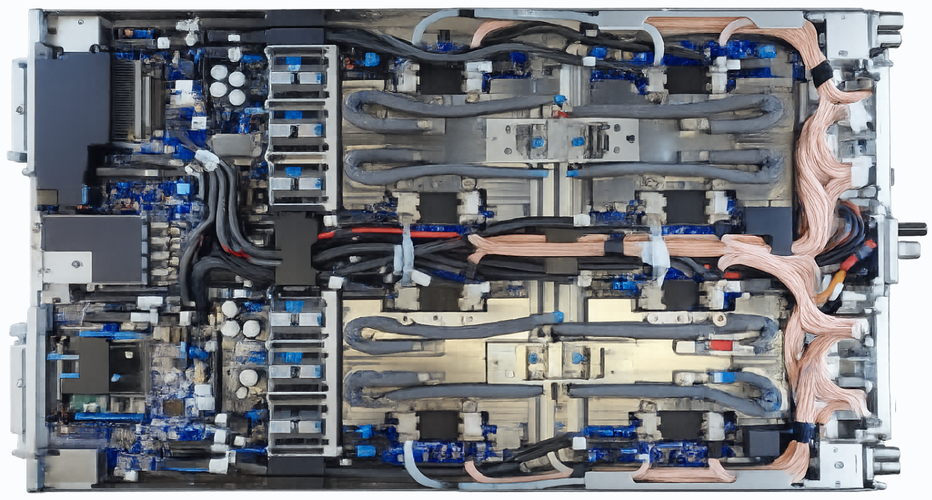

同一代产品的服务器托盘：计算组件、液冷管路、连接接口与供电共同构成系统。

图：Microsoft

Meta 产品实例 P24 · 实物照片

Meta MTIA：内部业务用加速器

Meta 第二代 MTIA，2024 年公布

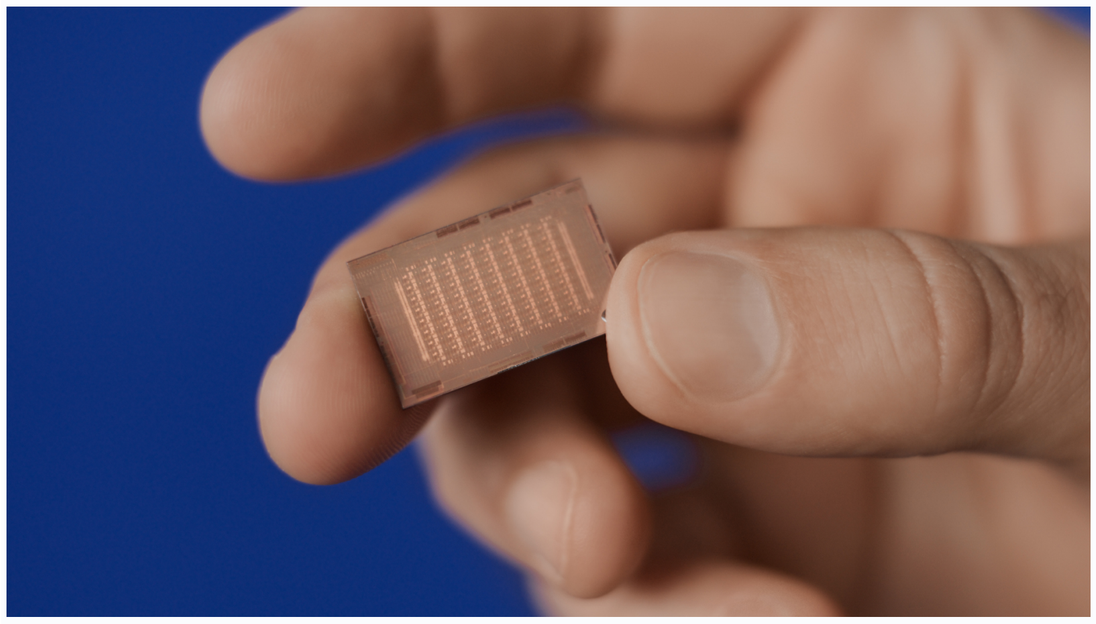

图为 Meta 官方公开的第二代 MTIA 实物，手指提供大小参照；照片不能证明内部采用 HBM。

图：Meta

AI 服务器如何组成：部件 → 节点 → 机架 → 集群

加速器之外，还需要主机、存储、互连、供电、散热，以及系统软件和整机验证。

计算与主机 CPU
Intel Xeon、AMD EPYC
NVIDIA Grace / Vera
操作系统、调度与数据预处理

加速器与 HBM
NVIDIA / AMD GPU
Google TPU / 云厂 ASIC
主计算任务与高速本地内存

主机内存
DDR5 RDIMM / MRDIMM
部分平台用 LPDDR / SOCAMM
Micron、Kingston、SMART 等

SSD / 共享存储
Micron、Samsung（韩）
Solidigm（SK hynix 旗下）等
系统：DDN、NetApp、VAST 等

板级互连 / 信号调理
Broadcom、Astera Labs
Marvell、Credo
PCIe / CXL、Switch、Retimer

网络芯片 / NIC / 光电
NVIDIA、Broadcom、Marvell
Credo：AEC / DSP
Coherent、Lumentum：光电

PCB / 连接 / 机械件
TTM：多层高速 PCB
Amphenol：连接器/线缆
以及全球机箱、背板制造商

板级供电 / 热管理
TI、MPS：电源控制/功率器件
PSU、风扇或液冷冷板
为各芯片与板卡供电、散热

整机 / 机架集成：多种供货路径并行
品牌与系统：Dell、HPE、Supermicro；ODM：Quanta/QCT、Wiwynn、Foxconn、Wistron（台）等
ODM 可供品牌商，也可直接服务云厂；装配、布线、固件、散热及负载测试后交付

集群网络设备与系统
Arista、Cisco、NVIDIA
HPE / Juniper
InfiniBand 或 Ethernet 等
交换芯片 / NIC / 光铜连接共同配合

AI 机架 / 服务器集群
机内与跨机架互连
节点调度、共享存储、故障管理
驱动/固件、CUDA/ROCm/厂商栈
交付自用或云端运营

机房供电 / 冷却 / 空间
Vertiv；Eaton（爱尔兰注册）
Schneider Electric（法）等
Equinix、Digital Realty 等机房
电力、UPS、配电、制冷与托管

明确供货例子：Broadcom Tomahawk 6 → Arista 交换机；NVIDIA 平台 → Dell PowerEdge 机架 → CoreWeave。

网络器件不等于整台交换机；板级电源芯片不等于机房 UPS/供配电。主机内存类型需与 CPU 平台匹配。

来源：S18、S35-S46。完整标题、链接及证据边界见图册附录。

服务器怎样装起来：内部、网络与机架

从服务器内部往外看，最后连接到集群网络和机房冷却。

对应分图 07：CPU / 内存 / 加速器 + 存储 / 网络 / 电源 → 整机 → 机架与集群

内部结构 P25 · 产品实物图

01 服务器内部的部件位置

Supermicro SYS-421GE-TNRT

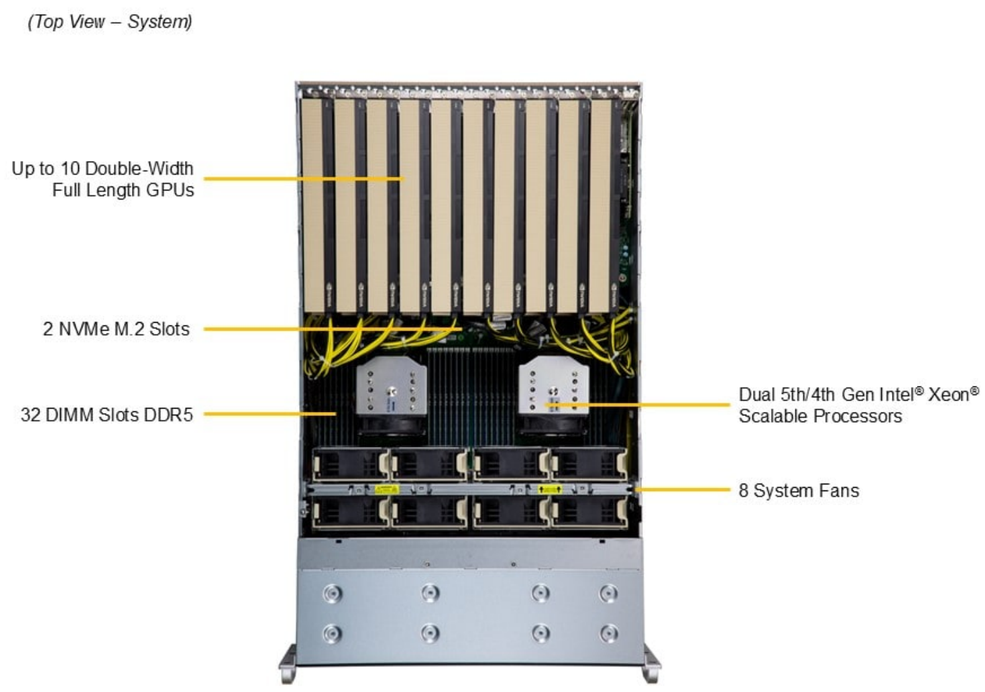

上方是 GPU 扩展区域，中间是 CPU 与两侧内存插槽，下方可见成排风扇和前端存储区域。

Supermicro 官方资料

整机 P26 · 产品实物图

02 完成装配的服务器

Supermicro SYS-421GE-TNRT

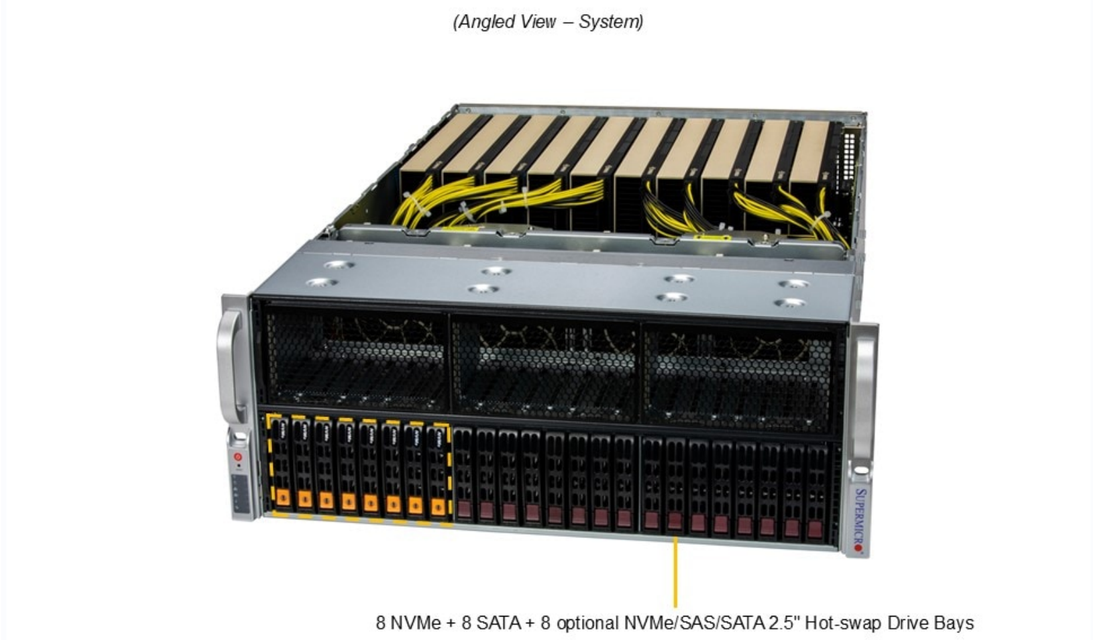

机箱内包含主机与加速器系统；前部有存储和进风区域。整机可上架部署。

Supermicro 官方资料

服务器网络 P30 · 官方产品图

03 DPU / 网卡的板卡形态

NVIDIA BlueField-3

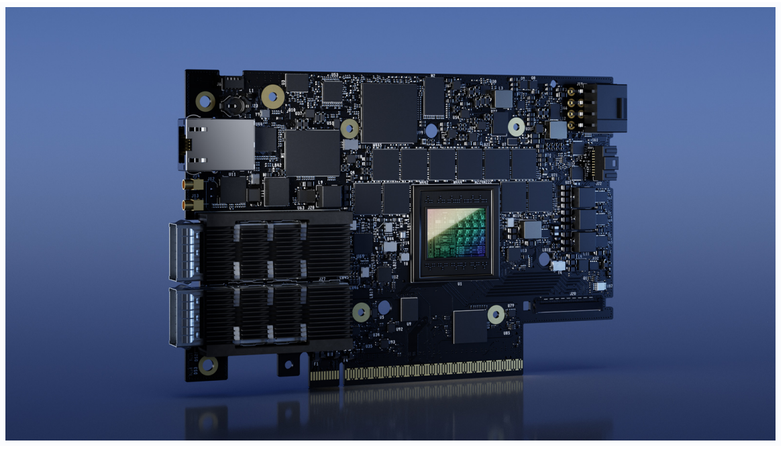

可看到 PCIe 金手指、网络接口和处理芯片；DPU 承担网络、存储、安全等卸载任务。

NVIDIA 官方资料

集群互连 P27 · 现场实拍

04 机架之间靠网络连接

CoreWeave / NVIDIA SN6600-LD

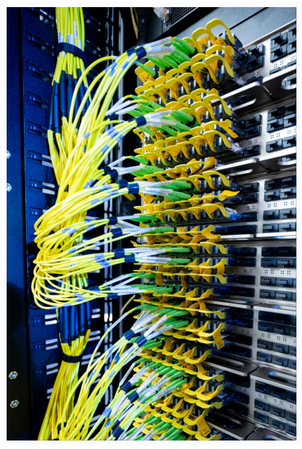

光纤接入交换设备，把计算节点组织成集群。这张图来自 CoreWeave 的网络部署现场。

CoreWeave / NVIDIA 官方资料

散热 P28 · 现场实拍

05 机架中的液冷管路

CoreWeave 液冷机架现场

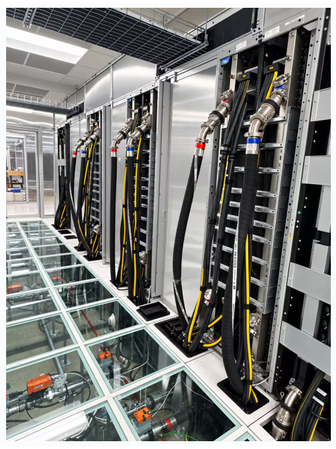

粗软管、红蓝快接头与地板下管路，把机架内热量输送到设施冷却系统。

CoreWeave 官方资料

冷却设施 P29 · 产品渲染图

06 冷却液分配单元 CDU

Vertiv CoolChip CDU 2300

CDU 在设施冷却回路与服务器回路之间管理换热和流体；它属于机房配套设备。

Vertiv 官方资料

CoreWeave 在哪里：服务器变成算力，再变成服务

硬件交付、机房托管、云算力和模型 API 是不同业务；下图按交付内容连接。

硬件交付
NVIDIA 平台 + Dell 机架
公开实例：PowerEdge XE9712
GB200 NVL72 液冷集成机架

机房 / 托管服务
Core Scientific → CoreWeave
提供 HPC 数据中心基础设施
这是托管合同关系

运营软件与工程
GPU 集群、存储网络、监控
Kubernetes / Slurm 调度
把硬件变成可租用、可运维的服务

AI 专用云：CoreWeave
整合服务器 + 机房 + 运营能力
向 AI 企业和其他客户出售算力
同类角色：Lambda、Crusoe 等
它本身已经是云服务厂商

综合云：自建与采购并存
AWS、Microsoft Azure
Google Cloud、Oracle OCI
直接购 GPU / 服务器；部分自研芯片
也可按项目采购外部算力

企业自用算力
Meta 等企业自有集群
运营自己的训练与推理任务
也可采购第三方算力
不必对外出售通用云实例

训练 / 推理算力

公开合作：CoreWeave → Microsoft（部分算力）

云实例 / 集群

模型研发 / 训练与推理
OpenAI、Anthropic、Google DeepMind 等
从一家或多家算力运营商采购，或结合自建资源
完成模型开发与持续运行

企业 / 开发者直接租用云资源
GPU / TPU / Trainium 实例、裸金属、托管集群
企业可以自行训练、微调和部署开源或自有模型
也可直接使用模型 API

模型 API / 托管模型平台
模型厂直供 API；云厂通过 Bedrock、Vertex AI、Foundry 等提供服务

模型 API

AI 应用 / 企业流程 / 最终用户
助手、搜索、编码、广告、客服、内容生成
例如 Microsoft、Google、Salesforce、ServiceNow 等

具体证据：CoreWeave → OpenAI / Microsoft；OCI → OpenAI；AWS / Google 的算力支持 Anthropic。云之间并非固定串行。

来源：S25、S44、S47-S53。完整标题、链接及证据边界见图册附录。

CoreWeave 的算力云：服务器背后的真实现场

硬件需要持续的网络、冷却、调度与工程运维，才能成为可交付的云服务。

对应分图 08：硬件 + 机房设施 + 运营能力 → 云算力 → 模型 / 企业 / 开发者

算力基础 P32 · 视频实拍画面

服务器集群：密集的连接与设备

CoreWeave 机房视频实拍

图为 CoreWeave 官方视频中的服务器后部，可看到扩展卡、线缆、网络连接和指示灯。

CoreWeave 官方资料

集群连接 P27 · 现场实拍

网络集群：连接多个计算机架

CoreWeave / NVIDIA 网络现场

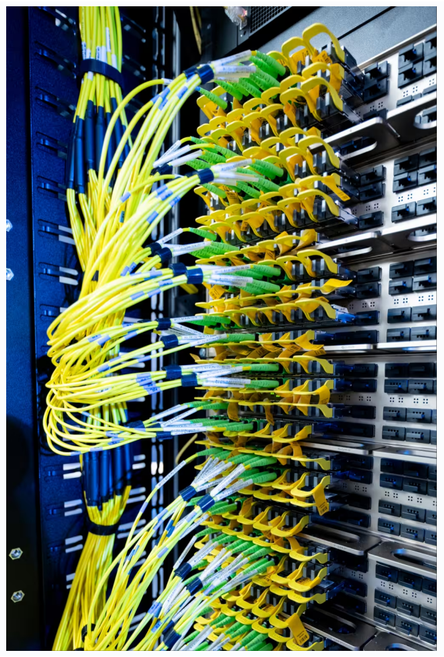

交换设备与密集光纤为集群提供数据通路；模型任务通常需要多节点协同。

CoreWeave / NVIDIA 官方资料

基础设施 P28 · 现场实拍

液冷设施：把热量带走

CoreWeave 液冷机架现场

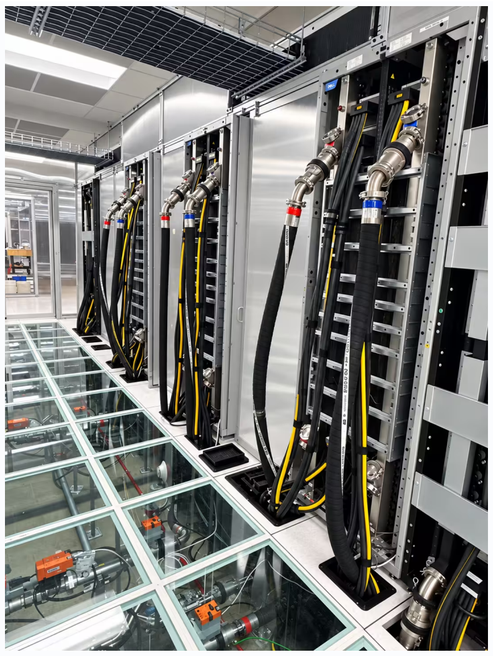

计算设备的运行需要持续供电和散热。照片展示了机架端管路和地板下的冷却连接。

CoreWeave 官方资料

云运营 P31 · 现场实拍

运维现场：持续保持集群可用

CoreWeave 工程运维现场

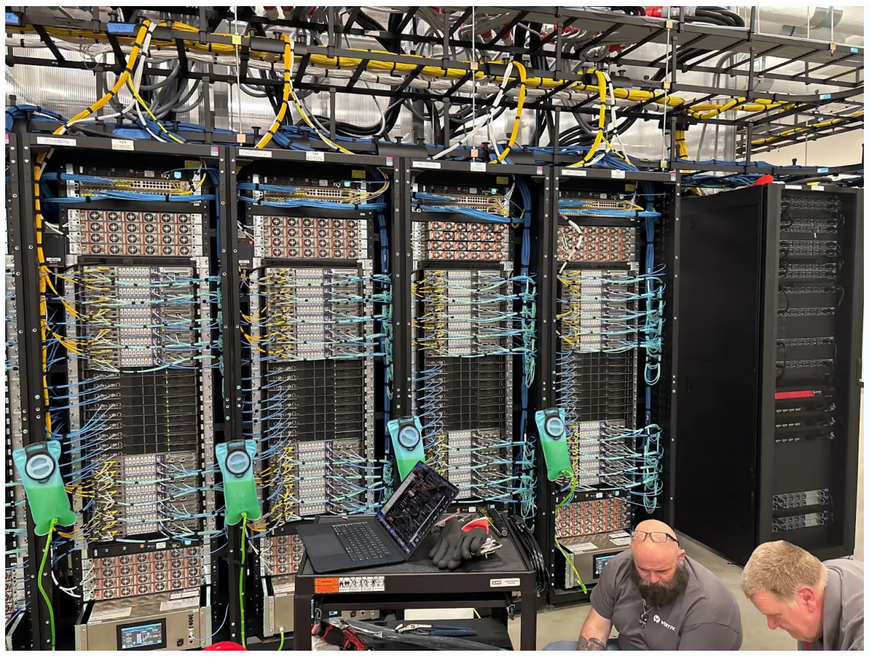

技术人员检查液冷系统；运维、监控和调度与硬件一起构成云运营商的交付能力。

CoreWeave 官方资料

公司对照 A：设计、材料与晶圆制造

A1

美国公司列为主线；境外公司保留关键供应环节。所在地/集团归属不等于工厂所在地，也不等于股票上市地。

模块	美国代表 / 美国业务主体	境外关键参与者 / 特别归属	向下游交付什么
EDA 软件	Synopsys（新思）、Cadence（楷登）	Siemens EDA（德国 Siemens 集团）	设计、仿真、验证、物理实现与签核工具 → 芯片设计公司
设计 IP	Rambus；SiFive	Arm（英国）	CPU 核、内存/高速接口及子系统授权 → SoC/ASIC 设计方
硅片与材料	Entegris；Qnity（原 DuPont 电子业务）	信越、SUMCO、味之素（日本）等	硅片、过滤/清洗/CMP 材料、封装绝缘材料 → 晶圆与封装厂
工艺设备	Applied Materials；Lam Research	ASML（荷兰）；Tokyo Electron、DISCO（日本）	光刻、沉积、刻蚀、清洗、减薄/切割设备 → 制造厂
检测与测试	KLA；Teradyne；FormFactor	Advantest（日本）	KLA 检测/量测；Teradyne 测试机；FormFactor 探针卡 → 制造与封测
晶圆制造	Intel Foundry；GlobalFoundries	TSMC（中国台湾）；Samsung Foundry（韩国）	逻辑与特色工艺晶圆 → 设计客户；具体制程按产品选择
封装与载板	Amkor	TSMC、ASE/SPIL、欣兴（中国台湾）；IBIDEN（日本）	封装集成、组测与载板：不同子环节 → 芯片/模组/系统

本目录列重要代表与分工，覆盖主要模块，不是全市场公司穷举、收入份额排名或特定产品的完整 BOM。

来源：各分图引用及来源目录。完整标题、链接及证据边界见图册附录。

A2

公司对照 B：计算芯片与内存产品

设计公司、存储原厂、模组品牌与接口芯片厂分层列示；同属内存领域并不等于承担相同制造任务。

模块	美国代表 / 美国业务主体	境外关键参与者 / 特别归属	向下游交付什么
GPU / CPU	NVIDIA；AMD；Intel	关键制造由全球代工/封装生态共同完成	GPU/CPU 封装、加速模组、平台 → 服务器与系统品牌
自研 AI ASIC	Google；AWS/Annapurna Labs；Microsoft；Meta	制造、存储及部分装配由境外伙伴参与	TPU / Trainium / Inferentia / Maia / MTIA → 各自平台
定制设计伙伴	Broadcom；Marvell	按项目整合全球制造与 IP 伙伴	共同设计、接口、封装协同与供货；不是晶圆代工厂
DRAM / HBM	Micron（美光）	SK hynix、Samsung（韩国）	DDR/LPDDR、GDDR 颗粒、HBM 堆栈 → 模组/加速器
服务器内存模组	Micron；Kingston；SMART Modular（Penguin Solutions）	SK hynix、Samsung 亦有原厂模组	RDIMM/MRDIMM 等 → CPU 主机内存；芯片需平台认证
DDR5 接口芯片	Rambus	Renesas（日本）；Montage/澜起（中国）	RCD/MRCD/MDB、PMIC、SPD Hub、TS → 内存模组厂
NAND / SSD	Micron；Sandisk（NAND 亦与 Kioxia 合作）	Kioxia（日本）；Samsung、SK hynix（韩国）；Solidigm（SK 旗下）	NAND + 控制器 + 固件 + PCB → SSD；再构成存储系统

本目录列重要代表与分工，覆盖主要模块，不是全市场公司穷举、收入份额排名或特定产品的完整 BOM。

来源：各分图引用及来源目录。完整标题、链接及证据边界见图册附录。

A3

公司对照 C：板卡、网络与系统集成

部件通常并行汇合：交换芯片、交换机、光模块、线缆和 NIC 分属不同子角色，不能画成一串公司接力。

模块	美国代表 / 美国业务主体	境外关键参与者 / 特别归属	向下游交付什么
显卡 / 板卡	NVIDIA 公版；PNY	ASUS、MSI、GIGABYTE（中国台湾）等	GPU + GDDR + PCB + 电源/散热 → PCIe 显卡
板级高速互连	Broadcom；Astera Labs；Marvell；Credo	全球封测、PCB、连接供应商共同参与	PCIe/CXL 交换/Retimer、AEC 等 → CPU/GPU/SSD/NIC 连接
网络芯片 / NIC	NVIDIA（ConnectX/BlueField）；Broadcom；Marvell	按产品接入全球制造生态	NIC/DPU、Ethernet 交换芯片等 → 服务器/交换设备
光电连接	Coherent；Lumentum；Credo（DSP/AEC 等）	海外光模块和连接制造商按系统要求配套	激光器、DSP、光模块、光/铜线缆 → 机架/集群互连
网络设备	Arista；Cisco；NVIDIA；HPE/Juniper	设备制造供应链全球化	交换机与网络系统 → AI 集群；例：Broadcom → Arista
PCB / 电源器件	TTM；Amphenol；TI；MPS	全球 PCB、PSU、冷板等制造商	PCB/连接器与板级电源芯片 → 主板/底板/加速器
服务器 / 机架	Dell；HPE；Supermicro	Quanta/QCT、Wiwynn、Foxconn、Wistron（中国台湾）等	设计、装配、固件和系统验证 → OEM/云厂/企业；ODM 可直供云厂

本目录列重要代表与分工，覆盖主要模块，不是全市场公司穷举、收入份额排名或特定产品的完整 BOM。

来源：各分图引用及来源目录。完整标题、链接及证据边界见图册附录。

A4

公司对照 D：数据中心、算力与应用

同一家公司可跨多个层级出现。下列模块按交付内容区分，不是互斥的公司分类，也不是固定交易顺序。

模块	美国代表 / 美国业务主体	境外关键参与者 / 特别归属	向下游交付什么
存储系统 / 软件	Dell、HPE、NetApp、DDN、VAST Data 等	全球 SSD 与网络供应商	共享/分布式数据存储、数据通路 → AI 集群
机架 / 机房配套	Vertiv；Eaton（美国起源，爱尔兰注册）	Schneider Electric（法国）；Delta（中国台湾）等	UPS、配电、PSU、冷却等，产品范围各有分工 → 数据中心
机房 / 托管	Equinix；Digital Realty；Core Scientific 等	云厂也可直接自建机房	空间、电力与冷却/托管 → 云运营者；不是统一出售 GPU 的角色
AI 专用云	CoreWeave；Lambda；Crusoe 等	亦有其他国家的专用算力运营商	GPU/集群、存储网络、调度运维 → 模型厂与企业
综合云	AWS；Microsoft Azure；Google Cloud；Oracle OCI	全球机房、硬件与服务网络	CPU/GPU/自研芯片实例、托管 AI 平台 → 企业/开发者/模型厂
模型与应用	OpenAI；Anthropic；Google；Meta；Microsoft 等	企业也可自建模型或用开源模型	模型研发/训练/推理 → 模型 API、托管平台 → 应用
应用终端	Microsoft、Google、Salesforce、ServiceNow 等	各行业软件公司、企业与个人	助手、搜索、编码、客服、内容和业务流程；可直接采购云算力

本目录列重要代表与分工，覆盖主要模块，不是全市场公司穷举、收入份额排名或特定产品的完整 BOM。

来源：各分图引用及来源目录。完整标题、链接及证据边界见图册附录。

R1

资料来源与证据边界

官方公告、公司产品文档、监管披露和原作者论文；检索截至 2026-10-18。来源目录 1/8。

S01 ASML：微芯片制造过程

支持多轮晶圆工艺及 fabless、代工、IDM 的分工。

https://www.asml.com/en/technology/all-about-microchips/how-microchips-are-made

S02 Synopsys 与 TSMC：EDA 与 IP 协作

支持设计工具、工艺适配、签核和多芯片设计的上游角色。

https://www.synopsys.com/partners/tsmc.html

S03 Cadence 与 TSMC：设计流程与 3D-IC

支持 EDA、IP、物理实现和先进封装协同设计。

https://www.cadence.com/en_US/home/company/newsroom/press-releases/pr/2025/cadence-and-tsmc-advance-ai-and-3d-ic-chip-design-with-certified.html

S04 Lam Research：工艺设备范围

沉积、刻蚀、去胶、清洗等设备参与晶圆制造。

https://www.lamresearch.com/products/our-processes/

S05 Applied Materials：半导体产品与工艺

支持沉积、CMP、刻蚀、金属加工等设备分类。

https://www.appliedmaterials.com/us/en/semiconductor/products.html

S06 KLA：FY2026 年报

支持检测、量测、过程控制与良率管理的角色。

https://ir.kla.com/sec-filings/annual-reports/content/0000319201-26-000027/klac-20260630.htm

S07 TSMC：3DFabric Alliance

包含 NVIDIA、AWS Trainium、存储、EDA、载板与封测合作说明。

https://pr.tsmc.com/english/news/2968

S08 Entegris：CMP 与材料纯度

支持抛光材料、清洗、过滤和污染控制等上游材料角色。

https://www.entegris.com/en/home/our-science/by-industry/microelectronics/semiconductor/cmp.html

S09 Qnity：独立公司成立公告

2025 年从 DuPont 分拆，材料业务应按当前公司身份标注。

https://www.qnityelectronics.com/news/qnity-launches-independent-co.html

公告中的合作和规划保留原有状态；公司级伙伴名单不自动等同于具体型号的实际采购或独家供货。

来源：以上为可点击原始链接。完整标题、链接及证据边界见图册附录。

R2

资料来源与证据边界

官方公告、公司产品文档、监管披露和原作者论文；检索截至 2026-10-18。来源目录 2/8。

S10 味之素：ABF 与半导体载板

ABF 是封装载板的绝缘材料；材料、载板、芯片制造分别分工。

https://www.ajinomoto.com/stories/the-ajinomoto-groups-unexpected-role-in-semiconductor-manufacturing-the-insulating-film-abf-born-from-aminoscience

S11 Kingston：DRAM 模组测试流程

直接列出 Micron、SK hynix、Samsung 颗粒供应；说明模组验证与老化。

https://www.kingston.com/en/blog/system-builder/reliable-quality-dram-testing

S12 Rambus：DDR5 芯片组说明

区分 RDIMM 和 MRDIMM；说明 RCD/MRCD/MDB、PMIC、SPD 与 TS。

https://www.rambus.com/blogs/complete-guide-to-ddr5-chipsets/

S13 Renesas：DDR5 Solutions

支持日本瑞萨的 DDR5 接口、管理、电源芯片产品角色。

https://www.renesas.com/en/products/memory-logic/memory-interface-products/ddr5-solutions

S14 澜起科技：DDR5 服务器产品

支持中国澜起的 RCD、MRCD/MDB、SPD、TS、PMIC 等角色。

https://www.montage-tech.com/cn/Memory_Interface/DDR5_Server

S15 Penguin Solutions：SMART Modular 产品组合

支持 SMART Modular 的模组业务及当前集团归属。

https://www.penguinsolutions.com/en-us/products/smart-modular-portfolio

S16 SK hynix：MR-MUF 堆叠技术

解释 TSV、堆叠、回流与填充；MR-MUF 是特定厂商路线。

https://news.skhynix.com/en/rulebreaker-revolutions-mr-muf-unlocks-hbm-heat-control/

S17 SK hynix：2026 TSMC 技术论坛

直接支持 SK hynix HBM4 基础裸片与 TSMC 逻辑工艺协作。

https://news.skhynix.com/en/tsmc-technology-symposium-2026/

S18 Micron：HBM4、SOCAMM2 与 SSD 量产公告

2026 年公开 HBM4 与 Vera Rubin、SOCAMM2 与 Vera 平台的产品关系。

https://micron.gcs-web.com/news-releases/news-release-details/micron-high-volume-production-hbm4-designed-nvidia-vera-rubin

公告中的合作和规划保留原有状态；公司级伙伴名单不自动等同于具体型号的实际采购或独家供货。

来源：以上为可点击原始链接。完整标题、链接及证据边界见图册附录。

R3

资料来源与证据边界

官方公告、公司产品文档、监管披露和原作者论文；检索截至 2026-10-18。来源目录 3/8。

S19 SK hynix：GTC 2026 产品与 NVIDIA 合作

公开 HBM3E 用于 GB300、GDDR7 用于 RTX 50；不代表独家供应。

https://news.skhynix.com/en/gtc-2026-exhibition-booth/

S20 Teradyne：Magnum 7H HBM 测试平台

支持 HBM 基础裸片与堆栈的多阶段测试；测试机不是存储原厂。

https://www.teradyne.com/products/magnum-7h/

S21 NVIDIA：RTX 50 系列与合作伙伴

支持 GDDR7、公版与 PNY、ASUS、MSI、GIGABYTE 等板卡参与者。

https://www.nvidia.com/en-us/geforce/news/rtx-50-series-graphics-cards-gpu-laptop-announcements/

S22 NVIDIA：Blackwell Ultra 技术说明

支持 TSMC 4NP、HBM3E、GPU/CPU 互连和机架构成，作为架构实例。

https://developer.nvidia.com/blog/inside-nvidia-blackwell-ultra-the-chip-powering-the-ai-factory-era/

S23 AMD：MI300X 系统文档

支持 OAM 模组、HBM3、UBB 底板与 Infinity Fabric 的物理层级。

https://instinct.docs.amd.com/projects/system-acceptance/en/latest/gpus/mi300x.html

S24 NVIDIA：RTX PRO 6000 Blackwell Server Edition

数据中心 GPU 使用 GDDR7 的明确例子，避免将服务器 GPU 全部等同于 HBM。

https://www.nvidia.com/en-us/data-center/rtx-pro-6000-blackwell-server-edition/

S25 Broadcom：2026-04-06 SEC 8-K

直接确认 Google TPU 开发/供应与机架组件合作；未来部署保留规划状态。

https://www.sec.gov/Archives/edgar/data/1730168/000119312526144028/d87999d8k.htm

S26 Google 作者论文：TPU v4，ISCA 2023

支持 ASIC+HBM、4 芯片 PCB、64 芯片机架、4096 芯片系统及 ICI/OCS。

https://suvinay.github.io/pubs/2023.tpu.isca.pdf

S27 Google Cloud：TPU 系统架构

支持 TPU、Pod、Slice、ICI/OCS 与云服务入口的关系。

https://docs.cloud.google.com/tpu/docs/system-architecture-tpu-vm

公告中的合作和规划保留原有状态；公司级伙伴名单不自动等同于具体型号的实际采购或独家供货。

来源：以上为可点击原始链接。完整标题、链接及证据边界见图册附录。

R4

资料来源与证据边界

官方公告、公司产品文档、监管披露和原作者论文；检索截至 2026-10-18。来源目录 4/8。

S28 Broadcom：FY2025 10-K

披露公司级代工及组测伙伴池，不等于某代 TPU 的完整供应清单。

https://www.sec.gov/Archives/edgar/data/1730168/000173016825000121/avgo-20251102.htm

S29 AWS：EC2 Trn2 产品页

支持 Trainium2、HBM3、16/64 芯片系统、NeuronLink、EFA 与云实例。

https://aws.amazon.com/ec2/instance-types/trn2/

S30 Marvell：与 AWS 的定制 AI 产品合作

仅确认公告所列合作范围，不能推出某代 Trainium 由 Marvell 独家设计。

https://www.marvell.com/company/newsroom/marvell-expands-strategic-collaboration-aws-enable-accelerated-infrastructure-ai-cloud.html

S31 Microsoft：Maia 200 官方发布

支持微软设计、TSMC 3nm、HBM3e、托盘、Ethernet 与 Azure 使用。

https://blogs.microsoft.com/blog/2026/01/26/maia-200-the-ai-accelerator-built-for-inference/

S32 Meta：与 Broadcom 定制芯片合作

2026 年公开芯片设计、先进封装和网络合作。

https://about.fb.com/news/2026/04/meta-partners-with-broadcom-to-co-develop-custom-ai-silicon/

S33 Meta：2024 年 MTIA 架构

公开 TSMC 5nm 与 LPDDR5；这套参数仅用于该代架构实例。

https://ai.meta.com/blog/next-generation-meta-training-inference-accelerator-AI-MTIA/

S34 OpenAI：与 Broadcom 的自研加速器合作

支持模型公司向芯片设计延伸；公告规划不能当作已完成交付。

https://openai.com/index/openai-and-broadcom-announce-strategic-collaboration/

S35 Astera Labs：AI 加速器底板方案

支持 PCIe/CXL、Retimer、Fabric Switch 等板级互连角色。

https://www.asteralabs.com/solutions/ai-servers-and-clustering/ai-accelerator-baseboard/

公告中的合作和规划保留原有状态；公司级伙伴名单不自动等同于具体型号的实际采购或独家供货。

来源：以上为可点击原始链接。完整标题、链接及证据边界见图册附录。

R5

资料来源与证据边界

官方公告、公司产品文档、监管披露和原作者论文；检索截至 2026-10-18。来源目录 5/8。

S36 Credo：PCIe AEC 与机架互连

支持有源电缆、信号调理及机架内部互连的角色。

https://credosemi.com/blogs/how-pcie-aecs-extend-stable-gen6-connectivity-across-the-rack/

S37 Coherent：Datacenter 产品

支持光器件、光模块与数据中心连接角色。

https://www.coherent.com/communications/datacom/datacenter

S38 Lumentum：Data Center 产品

支持激光器、光收发模块和 OCS；不同产品承担不同连接任务。

https://www.lumentum.com/en/products/data-center

S39 TTM：Computing Applications

支持 GPU、AI 加速器、服务器和高速网络 PCB 的制造角色。

https://www.ttm.com/index.php/en/markets-we-serve/computing/applications

S40 Amphenol：AI 互连产品

支持高速、电源、内存模组连接器和线缆。

https://amphenol.com/markets/it-datacom/artificial-intelligence?PageSize=10&pagenumber=4

S41 Texas Instruments：数据中心计算供电

支持芯片、主板、加速卡上的电源管理和功率级。

https://www.ti.com/applications/data-center/compute/overview.html

S42 MPS：MP29816-C 多相控制器

支持 CPU/GPU/SoC 的板级供电角色，与机房配电区分。

https://www.monolithicpower.com/en/products/mp29816-c.html

S43 Arista：1.6T AI 网络产品

公开 Broadcom Tomahawk 6 进入 Arista 交换机的具体关系。

https://www.arista.com/company/news/press-release/24102-pr-20260609

公告中的合作和规划保留原有状态；公司级伙伴名单不自动等同于具体型号的实际采购或独家供货。

来源：以上为可点击原始链接。完整标题、链接及证据边界见图册附录。

R6

资料来源与证据边界

官方公告、公司产品文档、监管披露和原作者论文；检索截至 2026-10-18。来源目录 6/8。

S44 CoreWeave / Dell：扩大战略合作

支持 NVIDIA 平台→Dell PowerEdge 机架→CoreWeave，含其调度和运维软件。

https://investors.coreweave.com/news/news-details/2024/CoreWeave-and-Dell-Technologies-Extend-Relationship-to-Deliver-AI-at-Scale/default.aspx

S45 Vertiv：NVIDIA GB300 电力与冷却参考架构

支持机架/机房电力和冷却配套；不推出向所有云机房供货。

https://investors.vertiv.com/news/news-details/2025/Vertiv-Develops-Energy-Efficient-Cooling-and-Power-Reference-Architecture-for-the-NVIDIA-GB300-NVL72-Platform-Available-as-SimReady-Assets-in-NVIDIA-Omniverse-Blueprint-for-AI-Factory-Design-and-Operations/default.aspx

S46 HPE：完成 Juniper 收购

2025-07-02 完成收购，目录将 Juniper 标在 HPE 体系内。

https://www.hpe.com/us/en/newsroom/press-release/2025/07/hewlett-packard-enterprise-closes-acquisition-of-juniper-networks-to-offer-industry-leading-comprehensive-cloud-native-ai-driven-portfolio.html

S47 CoreWeave：扩大 OpenAI 算力协议

支持 CoreWeave 直接为 OpenAI 提供模型训练和部署算力。

https://www.coreweave.com/news/coreweave-expands-agreement-with-openai-by-up-to-6-5b

S48 CoreWeave：SEC 招股书

支持 CoreWeave 的算力运营角色和 Microsoft 客户关系。

https://www.sec.gov/Archives/edgar/data/1769628/000119312525067651/d899798d424b4.htm

S49 Core Scientific：为 CoreWeave 提供托管设施

支持设施/托管→CoreWeave 的交付关系，与芯片制造区分。

https://investors.corescientific.com/news-events/press-releases/detail/74/core-scientific-to-provide-approximately-200-mw-of-infrastructure-to-host-coreweaves-high-performance-computing-services-capturing-significant-ai-compute-opportunity

S50 Anthropic：Google / Broadcom 算力合作

说明使用多类芯片/多家云，以及 Claude 在三大云平台的模型分发。

https://www.anthropic.com/news/google-broadcom-partnership-compute

S51 OpenAI：Intelligence Age 算力基础设施

支持 OCI 和 NVIDIA GB200 在 OpenAI 基础设施中的实例。

https://openai.com/index/building-the-compute-infrastructure-for-the-intelligence-age/

公告中的合作和规划保留原有状态；公司级伙伴名单不自动等同于具体型号的实际采购或独家供货。

来源：以上为可点击原始链接。完整标题、链接及证据边界见图册附录。

R7

资料来源与证据边界

官方公告、公司产品文档、监管披露和原作者论文；检索截至 2026-10-18。来源目录 7/8。

S52 NVIDIA：Vera Rubin 系统与伙伴生态

支持美国系统品牌、台湾 ODM 和云运营商共同组成的生态。

https://nvidianews.nvidia.com/news/vera-rubin-full-production-agentic-ai-factory

S53 Core Scientific：终止 CoreWeave 合并协议

2025-10-30 终止拟议合并；图中保留托管关系，不画为母子公司。

https://investors.corescientific.com/sec-filings/all-sec-filings/content/0001140361-25-039808/ef20057995_ex99-1.htm

S54 FormFactor：HBM 与晶圆级测试

支持已知良品裸片筛选及先进封装中多阶段测试。

https://www.formfactor.com/applications/high-volume-test-on-wafer/advanced-packaging/

S55 SUMCO：硅片制造工艺

支持单晶生长、切片、抛光与清洗后向晶圆制造提供硅片。

https://www.sumcosi.com/english/products/process/

S56 Intel Foundry：系统代工与封装服务

支持 Intel Foundry 的晶圆、先进封装和系统组测角色，不指定未公开客户。

https://www.intel.com/content/www/us/en/foundry/library/fact-sheet.html

S57 Samsung：先进封装

支持 Samsung Foundry 的异质集成和先进封装业务。

https://semiconductor.samsung.com/foundry/advanced-package/

S58 GlobalFoundries：硅光子技术

支持特色代工/硅光子角色；不把其与最先进 GPU 工艺简单等同。

https://gf.com/technologies/silicon-photonics/

S59 Arm：Neoverse Compute Subsystems

支持 Arm 在云与数据中心 CPU IP、互连及子系统上的角色。

https://www.arm.com/products/cloud-datacenter/neoverse-compute-subsystems

公告中的合作和规划保留原有状态；公司级伙伴名单不自动等同于具体型号的实际采购或独家供货。

来源：以上为可点击原始链接。完整标题、链接及证据边界见图册附录。

R8

资料来源与证据边界

官方公告、公司产品文档、监管披露和原作者论文；检索截至 2026-10-18。来源目录 8/8。

S60 SiFive：RISC-V 核心 IP

支持美国 RISC-V 设计 IP 公司在设计上游的位置。

https://www.sifive.com/risc-v-core-ip

S61 Kioxia：Data Center SSD

说明 NAND、固件、控制器及面向云的 SSD 产品组成。

https://www.kioxia.com/en-jp/business/ssd/data-center-ssd.html

S62 Solidigm：Data Center SSD

支持企业级 SSD 角色；Solidigm 归属 SK hynix 集团。

https://www.solidigm.com/products/data-center.html

S63 Equinix：AI Infrastructure

支持互连、托管与基础设施角色，不等同于 AI 芯片制造商。

https://www.equinix.com/product-solutions/ai

S64 Digital Realty：NVIDIA 数据中心合作

支持适配 AI 的数据中心空间、电力和冷却设施角色。

https://www.digitalrealty.com/partners/nvidia

S65 Kioxia / Sandisk：用于 AI 的 QLC 闪存

支持两家公司的 NAND 技术协作，以及 NAND 与 DRAM/HBM 的区别。

https://www.kioxia.com/en-jp/about/news/2026/20260812-1.html

S66 Lambda：AI Cloud Platform

支持专用 GPU 云和大规模 GPU 集群服务的公司角色。

https://lambda.ai/cloud

S67 Crusoe：Infrastructure Cloud

支持 GPU/CPU、存储、网络、Kubernetes/Slurm 等算力运营能力。

https://docs.cloud.crusoe.ai/infrastructure-cloud/overview/index.html

公告中的合作和规划保留原有状态；公司级伙伴名单不自动等同于具体型号的实际采购或独家供货。

来源：以上为可点击原始链接。完整标题、链接及证据边界见图册附录。

PHOTO SOURCES / 2026.10.18

实物配图来源与识别说明

图片旁的 P 编号对应这里；网页标题与原始图片地址另附于源文件表。

P01 TWINSCAN NXE:3400C

ASML | 官方产品图 | 原图 1920 × 1080

https://www.asml.com/en/products/euv-lithography-systems/twinscan-nxe3400c

P02 Endura PVD 200mm 平台示例

Applied Materials | 实物照片 | 原图 2572 × 2012

https://www.appliedmaterials.com/us/en/product-library/endura-pvd.html

P03 Versys Kiyo45

Lam Research | 实物照片 | 原图 500 × 457

https://newsroom.lamresearch.com/A-New-Life-for-Older-Equipment?blog=true

P04 3935 / 2965 BBP 检测设备

KLA | 官方产品图 | 原图 1200 × 675

https://www.linkedin.com/posts/klacorp_bbp-inspectors-are-a-unique-class-of-optical-activity-7203785347300794368-rirH

P05 Magnum 7H

Teradyne | 官方产品图 | 原图 779 × 461

https://www.teradyne.com/products/magnum-7h/

P06 设备制造洁净室现场，2020 年文章

ASML | 现场实拍 | 原图 1440 × 1080

https://www.asml.com/en/company/stories/2020/inside-high-tech-manufacturing

P07 DRAM 晶圆：尚未切成独立芯片

Micron Technology；由 IEEE Spectrum 发布 | 实物照片 | 原图 2000 × 1500

https://spectrum.ieee.org/micron-dram

P08 单颗 DDR5 DRAM 封装：正面与底面

Samsung Electronics | 官方产品图 | 原图 1000 × 563

https://news.samsung.com/global/samsung-electronics-develops-industrys-first-12nm-class-ddr5-dram

保留原图内容、纵横比、厂商标识与出处；结构示意和产品渲染不标成生产现场照片。

PHOTO SOURCES / 2026.10.18

实物配图来源与识别说明

图片旁的 P 编号对应这里；网页标题与原始图片地址另附于源文件表。

P09 内存模组生产与测试现场

Kingston Technology | 实物照片 | 原图 450 × 320

https://www.kingston.com/en/blog/system-builder/reliable-quality-dram-testing

P10 DDR5 RDIMM 成品：内存颗粒组成一条模组

Micron Technology；由 Mynavi TECH+ 发布 | 官方产品图 | 原图 1200 × 756

https://news.mynavi.jp/techplus/article/20240514-2945507/

P11 HBM 堆叠内部：TC-NCF 与 MR-MUF 对照

SK hynix | 结构示意 | 原图 1000 × 666

https://news.skhynix.com/en/rulebreaker-revolutions-mr-muf-unlocks-hbm-heat-control/

P12 HBM3E 堆栈产品外观

SK hynix | 官方产品图 | 原图 1000 × 657

https://news.skhynix.com/en/sk-hynix-begins-volume-production-of-industry-first-hbm3e/

P13 真实展品：HBM4 晶圆与 HBM、DDR5、GDDR 产品

SK hynix | 实物照片 | 原图 1600 × 900

https://news.skhynix.com/en/dtf-2026/

P14 内存条装进服务器：Dell PowerEdge R770

SK hynix | 实物照片 | 原图 1600 × 900

https://news.skhynix.com/en/dtf-2026/

P15 NVIDIA H100 SXM5 模组

NVIDIA | 产品渲染图 | 原图 1672 × 941

https://developer.nvidia.com/blog/nvidia-hopper-architecture-in-depth/

P16 GeForce RTX 5090 Founders Edition

NVIDIA | 产品渲染图 | 原图 1280 × 720

https://www.nvidia.com/en-us/geforce/graphics-cards/50-series/rtx-5090/

保留原图内容、纵横比、厂商标识与出处；结构示意和产品渲染不标成生产现场照片。

PHOTO SOURCES / 2026.10.18

实物配图来源与识别说明

图片旁的 P 编号对应这里；网页标题与原始图片地址另附于源文件表。

P17 GB300 Grace Blackwell Ultra Superchip

NVIDIA | 官方产品图 | 原图 1294 × 942

https://developer.nvidia.com/blog/inside-nvidia-blackwell-ultra-the-chip-powering-the-ai-factory-era/

P18 Google TPU v4 封装

Google；Jouppi 等作者 | 实物照片 | 原图 686 × 680

https://suvinay.github.io/pubs/2023.tpu.isca.pdf

P19 Google TPU v4 四芯片板

Google；Jouppi 等作者 | 实物照片 | 原图 2048 × 1536

https://suvinay.github.io/pubs/2023.tpu.isca.pdf

P20 Google TPU v4 Pod 的八个机架

Google；Jouppi 等作者 | 实物照片 | 原图 2048 × 581

https://suvinay.github.io/pubs/2023.tpu.isca.pdf

P21 AWS Trainium2 芯片封装

Amazon / AWS | 实物照片 | 原图 2000 × 1125

https://www.aboutamazon.com/stories/ai-chips-aws-trainium2-explain

P22 Microsoft Maia 200 芯片封装

Microsoft | 实物照片 | 原图 1260 × 708

https://blogs.microsoft.com/blog/2026/01/26/maia-200-the-ai-accelerator-built-for-inference/

P23 Microsoft Maia 200 服务器刀片 / 托盘

Microsoft | 实物照片 | 原图 1536 × 1024

https://blogs.microsoft.com/blog/2026/01/26/maia-200-the-ai-accelerator-built-for-inference/

P24 Meta 第二代 MTIA（2024 年公布）

Meta | 实物照片 | 原图 1920 × 1080

https://about.fb.com/news/2024/04/introducing-our-next-generation-infrastructure-for-ai/

保留原图内容、纵横比、厂商标识与出处；结构示意和产品渲染不标成生产现场照片。

PHOTO SOURCES / 2026.10.18

实物配图来源与识别说明

图片旁的 P 编号对应这里；网页标题与原始图片地址另附于源文件表。

P25 SYS-421GE-TNRT

Supermicro | 产品实物图 | 原图 960 × 720

https://www.supermicro.com/en/products/system/GPU/4U/SYS-421GE-TNRT

P26 SYS-421GE-TNRT

Supermicro | 产品实物图 | 原图 960 × 720

https://www.supermicro.com/en/products/system/GPU/4U/SYS-421GE-TNRT

P27 NVIDIA Spectrum-X SN6600-LD

CoreWeave / NVIDIA | 现场实拍 | 原图 1011 × 1516

https://www.coreweave.com/blog/liquid-cooled-switching-doubles-ai-network-bandwidth-per-rack

P28 CoreWeave 液冷机架（图中可见 Dell 标识）

CoreWeave | 现场实拍 | 原图 1086 × 1448

https://www.coreweave.com/blog/what-it-takes-to-bring-up-a-multi-rack-nvidia-vera-rubin-nvl72-cluster

P29 CoolChip CDU 2300

Vertiv | 产品渲染图 | 原图 1000 × 1000

https://www.vertiv.com/en-us/products-catalog/thermal-management/high-density-solutions/vertiv-coolchip-cdu/

P30 BlueField-3 DPU

NVIDIA | 官方产品图 | 原图 1600 × 900

https://nvidianews.nvidia.com/file/nvidia-bluefield-3-dpu243116

P31 数据中心液冷运维现场

CoreWeave | 现场实拍 | 原图 1600 × 1200

https://coreweave.com/blog/why-you-need-liquid-cooling-for-ai-performance-at-scale

P32 官方机房视频中的服务器后部

CoreWeave | 视频实拍画面 | 原图 1280 × 720

https://www.coreweave.com/resources/videos/the-ai-data-center-behind-coreweave-the-essential-cloud-for-ai

保留原图内容、纵横比、厂商标识与出处；结构示意和产品渲染不标成生产现场照片。